

2 최소 제곱법

● 최소 제곱법 – 기울기 a 구하기

- 이제 우리 목표는 가장 정확한 선을 긋는 것
- 더 구체적으로는 정확한 기울기 a 와 정확한 y 절편 b 를 알아내면 된다고 했음
- 만일 우리가 최소 제곱법(method of least squares)이라는 공식을 알고 적용한다면, 이를 통해 일차 함수의 기울기 a 와 y 절편 b 를 바로 구할 수 있음
- 지금 가진 정보가 x 값(입력 값, 여기서는 ‘공부한 시간’)과 y 값(출력 값, 여기서는 ‘성적’)일 때 이를 이용해 기울기 a 를 구하는 방법은 다음과 같음

$$a = \frac{(x - x \text{ 평균})(y - y \text{ 평균}) \text{의 합}}{(x - x \text{ 평균})^2 \text{의 합}} \quad (\text{식 4.1})$$

- 이것이 바로 최소 제곱법 공식
- 쉽게 풀어서 다시 쓰면 x 의 편차(각 값과 평균과의 차이)를 제곱해서 합한 값을 분모로 놓고, x 와 y 의 편차를 곱해서 합한 값을 분자로 놓으면 기울기가 나온다는 의미
- 다음은 y 절편인 b 를 구하는 공식

$$b = y \text{의 평균} - (x \text{의 평균} \times \text{기울기 } a) \quad (\text{식 4.2})$$

2 최소 제곱법

● 최소 제곱법

- 우리는 이미 y 평균, x 평균, 그리고 조금 전 구한 기울기 a 까지 이 식을 풀기 위해 필요한 모든 변수를 알고 있음

$$\begin{aligned} b &= 90.5 - (2.3 \times 5) \\ &= 79 \end{aligned}$$

- 이제 다음과 같이 예측 값을 구하기 위한 직선의 방정식이 완성

$$y = 2.3x + 79$$

- 이 식에 우리가 가진 데이터를 대입해 보면 x 를 대입했을 때 나오는 y 값을 ‘예측 값’이라고 하겠음

▼ 표 4-2 | 최소 제곱법 공식으로 구한 성적 예측 값


공부한 시간	2	4	6	8
성적	81	93	91	97
예측 값	83.6	88.2	92.8	97.4

3 평균 제공 오차

- 평균 제공 오차

- 그림 4-6과 같은 임의의 직선이 어느 정도의 오차가 있는지 확인하려면 각 점과 그래프 사이의 거리를 재면 됨

▼ 그림 4-7 | 임의의 직선과 실제 값 사이의 거리



3 평균 제곱 오차

● 평균 제곱 오차 (MSE)

- 그래프의 기울기가 잘못 되었을수록 빨간색 선의 거리의 합, 즉 오차의 합도 커짐
- 만일 기울기가 무한대로 커지면 오차도 무한대로 커지는 상관관계가 있는 것을 알 수 있음
- 빨간색 선의 거리의 합을 실제로 계산해 보자
- 거리는 입력 데이터에 나와 있는 y 의 ‘실제 값’과 x 를 $y = 3x + 76$ 식에 대입해서 나오는 ‘예측 값’의 차이를 이용해 구할 수 있음

$$\text{오차} = \text{실제 값} - \text{예측 값}$$

▼ 표 4-3 | 주어진 데이터에서 오차 구하기

공부한 시간(x)	2	4	6	8
성적(실제 값, y)	81	93	91	97
예측 값	82	88	94	100
오차	-1	5	-3	-3

- $MSE = 11.0$

3 평균 제곱 오차

● 평균 제곱 오차

- 이 값은 오차가 실제로 얼마나 큰지를 가늠하기에는 적합하지 않음
- 오차에 양수와 음수가 섞여 있어 오차를 단순히 더해 버리면 합이 0이 될 수도 있기 때문임
- 부호를 없애야 정확한 오차를 구할 수 있음
- 오차의 합을 구할 때는 각 오차 값을 제곱해 줌

$$\text{오차의 합} = \sum_i^n (y_i - \hat{y}_i)^2$$

- 여기서 i 는 x 가 나오는 순서를, n 은 x 원소의 총 개수를 의미
- 우리가 구하고자 하는 평균 제곱 오차는 위에서 구한 오차의 합을 n 으로 나눈 것

$$\text{평균 제곱 오차(MSE)} = \frac{1}{n} \sum (y_i - \hat{y}_i)^2$$


- 선형 회귀란 임의의 직선을 그어 이에 대한 평균 제곱 오차를 구하고, 이 값을 가장 작게 만들어 주는 a 값과 b 값을 찾아가는 작업

1 경사 하강법의 개요

● 경사 하강법의 개요

- 기울기 a 를 너무 크게 잡으면 오차가 커지고 기울기를 너무 작게 잡아도 오차가 커짐
- 이때 기울기가 무한대로 커지거나 무한대로 작아지면 그래프는 y 축과 나란한 직선이 됨
- 오차도 함께 무한대로 커짐
- 기울기 a 와 오차 사이에는 그림 5-1의 빨간색 그래프와 같은 이차 함수의 관계가 있다는 의미

▼ 그림 5-1 | 기울기 a 와 오차의 관계: 적절한 기울기(m 값)를 찾았을 때 오차가 최소화된다




기울기 a 값이 m 일때
오차가 최소값이 됨
즉, 기울기 a 와 오차사이의
이차 함수의 최소값이다

그리고 m 일때의 미분값은 0이다
즉, 기울기가 0이다

1 경사 하강법의 개요

▼ 그림 5-3 | 최솟점 m 을 찾아가는 과정



2 파이썬 코딩으로 확인하는 선형 회귀

- 파이썬 코딩으로 확인하는 선형 회귀

- 먼저 평균 제곱 오차의 식을 다시 가져와 보자

$$\frac{1}{n} \sum (y_i - \hat{y}_i)^2$$

- 여기서 $\hat{y}_i$ 는 $y = ax + b$ 의 식에 x_i 를 집어넣었을 때 값이므로 $\hat{y}_i = ax_i + b$ 를 대입하면 다음과 같이 바뀜

$$\frac{1}{n} \sum (y_i - (ax_i + b))^2$$

- 실제값 y_i 와 x_i 값은 우리가 이미 알고 있는 값임, a , b 값은 초기값 0 으로 학습을 시작함
- 이 값을 미분할 때 우리가 궁금한 것은 a 와 b 라는 것을 기억해야 함
- 식 전체를 미분하는 것이 아니라 필요한 값을 중심으로 미분해야 하기 때문임

$$a \text{로 편미분한 결과} = \frac{2}{n} \sum -x_i(y_i - (ax_i + b))$$

$$b \text{로 편미분한 결과} = \frac{2}{n} \sum -(y_i - (ax_i + b))$$

2 파이썬 코딩으로 확인하는 선형 회귀

미분의 기본 공식

1 | $f(x) = x$ 일 때 $f'(x) = 1$

2 | $f(x) = a$ 에서 a 가 상수일 때 $f'(x) = 0$

3 | $f(x) = ax$ 에서 a 가 상수일 때 $f'(x) = a$

4 | $f(x) = x^a$ 에서 a 가 자연수일 때 $f'(x) = ax^{a-1}$

5 | $f(g(x))$ 에서 $f(x)$ 와 $g(x)$ 가 미분 가능할 때 $\{f(g(x))\}' = f'(g(x)) \times g'(x)$

5. 체인 룰(Chain Rule, 연쇄법칙) 겹미분을 먼저 한뒤, 괄호안의 식을 속미분하여 곱해줌

기울기 a 편미분하기

$$E = \frac{1}{n} \sum_{i=1}^n (y_i - (ax_i + b))^2$$

이 식을 a 에 대해 편미분할 때는 **체인 룰(Chain Rule, 연쇄법칙)**을 사용합니다. 겉미분을 먼저 한 뒤, 괄호 안의 식을 a 로 속미분하여 곱해줍니다.

편미분 단계별 과정

1. 겉미분 적용하기

괄호의 제곱 $(\dots)^2$ 을 미분하여 2가 앞으로 내려옵니다.

$$\frac{\partial E}{\partial a} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (ax_i + b)) \cdot \frac{\partial}{\partial a} (y_i - (ax_i + b))$$

2. 속미분 계산하기

괄호 안의 식 $y_i - ax_i - b$ 를 a 로 편미분합니다. a 가 없는 y_i 와 b 는 상수가 되어 사라지고, $-ax_i$ 를 a 로 미분하면 $-x_i$ 만 남습니다.

$$\frac{\partial}{\partial a} (y_i - ax_i - b) = -x_i$$

2 파이썬 코딩으로 확인하는 선형 회귀

3. 식 정리하기

겉미분 결과에 속미분 결과인 $-x_i$ 를 곱해줍니다.

$$\frac{\partial E}{\partial a} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (ax_i + b)) \cdot (-x_i)$$

상수 2와 마이너스(-) 부호를 시그마($\sum$) 앞으로 빼서 최종 정리합니다.

$$\frac{\partial E}{\partial a} = -\frac{2}{n} \sum_{i=1}^n x_i(y_i - (ax_i + b))$$

편향 b 편미분하기

편미분 단계별 과정

1. 겉미분 적용하기

괄호의 제곱 (...)²을 미분하여 2가 시그마 앞으로 내려옵니다.

$$\frac{\partial E}{\partial b} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (ax_i + b)) \cdot \frac{\partial}{\partial b} (y_i - (ax_i + b))$$

2. 속미분 계산하기

괄호 안의 식 $y_i - ax_i - b$ 를 b 로 편미분합니다. b 가 없는 y_i 와 ax_i 는 상수가 되어 사라지고, $-b$ 를 b 로 미분하면 -1 이 됩니다.

$$\frac{\partial}{\partial b} (y_i - ax_i - b) = -1$$

편향 b 편미분하기

3. 식 정리하기

겉미분 결과에 속미분 결과인 -1 을 곱해줍니다.

$$\frac{\partial E}{\partial b} = \frac{1}{n} \sum_{i=1}^n 2(y_i - (ax_i + b)) \cdot (-1)$$

상수 2와 마이너스(-) 부호를 시그마 앞으로 빼서 최종 식을 완성합니다.

$$\frac{\partial E}{\partial b} = -\frac{2}{n} \sum_{i=1}^n (y_i - (ax_i + b))$$

이렇게 구한 a 와 b 의 편미분 결과는 경사하강법에서 모델의 가중치를 업데이트할 때 다음과 같이 사용됩니다.

- $a \leftarrow a - \eta \frac{\partial E}{\partial a}$
- $b \leftarrow b - \eta \frac{\partial E}{\partial b}$ (단, η 는 학습률)

3 다중 선형 회귀의 개요

- 다중 선형 회귀의 개요

- 더 정확한 예측을 하려면 추가 정보를 입력해야 하며, 정보를 추가해 새로운 예측 값을 구하려면 변수 개수를 늘려 다중 선형 회귀를 만들어 주어야 함

▼ 표 5-1 | 공부한 시간, 과외 수업 횟수에 따른 성적 데이터

공부한 시간(x_1)	2	4	6	8
과외 수업 횟수(x_2)	0	4	2	3
성적(y)	81	93	91	97

- 독립 변수가 x_1 과 x_2 , 이렇게 두 개 생긴 것
- 이를 사용해 종속 변수 y 를 만들 경우 기울기를 두 개 구해야 하므로 다음과 같은 식이 나옴

$$y = a_1x_1 + a_2x_2 + b$$

5 텐서플로에서 실행하는 선형 회귀, 다중 선형 회귀 모델

● 텐서플로에서 실행하는 선형 회귀, 다중 선형 회귀 모델

- 평균 제곱 오차처럼 실제 값과 예측 값 사이의 오차에 대한 식을 손실 함수(lossfunction)

평균 제곱 오차 → 손실 함수(loss function)

- 최적의 기울기와 절편을 찾기 위해 앞서 경사 하강법을 배웠음
- 딥러닝에서는 이를 옵티마이저(optimizer)라고 함 – 최적화 함수
- 우리가 사용했던 경사 하강법은 딥러닝에서 사용하는 여러 옵티마이저 중 하나였음

경사 하강법 → 옵티마이저(optimizer)

- 이제부터는 손실 함수, 옵티마이저라는 용어를 사용해 설명하겠음
- 먼저 텐서플로에 포함된 케라스 API 중 필요한 함수들을 다음과 같이 불러옴

```
from tensorflow.keras.models import Sequential
from tensorflow.keras.layers import Dense
```

2 시그모이드 함수


● 시그모이드 함수

- 이러한 S자 형태로 그래프가 그려지는 함수가 있는데 바로 시그모이드 함수(sigmoid function)
- 시그모이드 함수를 이용해 로지스틱 회귀를 풀어 나가는 공식은 다음과 같음

$$y = \frac{1}{1 + e^{-(ax+b)}}$$

- 이 식을 통해 알 수 있는 것은 우리가 구해야 하는 값이 여기서도 결국 $ax + b$ 라는 것
- 먼저 a 는 그래프의 경사도를 결정

▼ 그림 6-3 | a 값이 클 때와 작을 때의 그래프 변화




2 시그모이드 함수

- 시그모이드 함수

- b 는 그래프의 좌우 이동을 의미

▼ 그림 6-4 | b 값이 클 때와 작을 때의 그래프 변화




- a 값과 b 값에 따라 오차가 변함

4 로그 함수

● 로그 함수

- ‘3장. 딥러닝을 위한 기초 수학’의 로그 함수에서 배운 그래프를 다시 가져오겠음

▼ 그림 6-8 | 실제 값이 1일 때(파란색)와 0일 때(빨간색) 로그 함수 그래프



$$-\left\{ \underbrace{y \log h}_A + \underbrace{(1-y) \log(1-h)}_B \right\}$$

교차 엔트로피 오차
(cross entropy error)
함수