5주차

세상의 많은 현상은 정규분포를 따른다

참고 자료 및 일부 이미지 출처: 천재교육 <확률과통계(류희찬 저)>

일부 실습 데이터 출처: 엑셀로 풀어보는 생활 속의 통계학(안기수, 2021)>

2026-9-28

학습할 내용

- 이항분포
- 정규분포
- 기술통계량

‘반복 시행의 확률 구조’를 최초로 수학적으로 정식화한 모델, 이항분포!

이항분포는 **①각 시행은 성공/실패 두 결과 ②시행들이 독립 ③성공확률 p가 매 시행 동일인 시행이 n번 반복될 때 특정 횟수만큼 성공할 확률’을 수학적으로 표현**한 모델

$$P(X = k) = nCk \times p^k \times (1-p)^{n-k}$$

- n = 시행 횟수 (number of trials)
- k = 성공 횟수 (number of successes)
- p = 성공 확률 (probability of success)
- (1−p) = 실패 확률 (probability of failure)
- $nCk = \frac{n!}{k!(n-k)!}$ = n번 중 k번을 선택하는 경우의 수

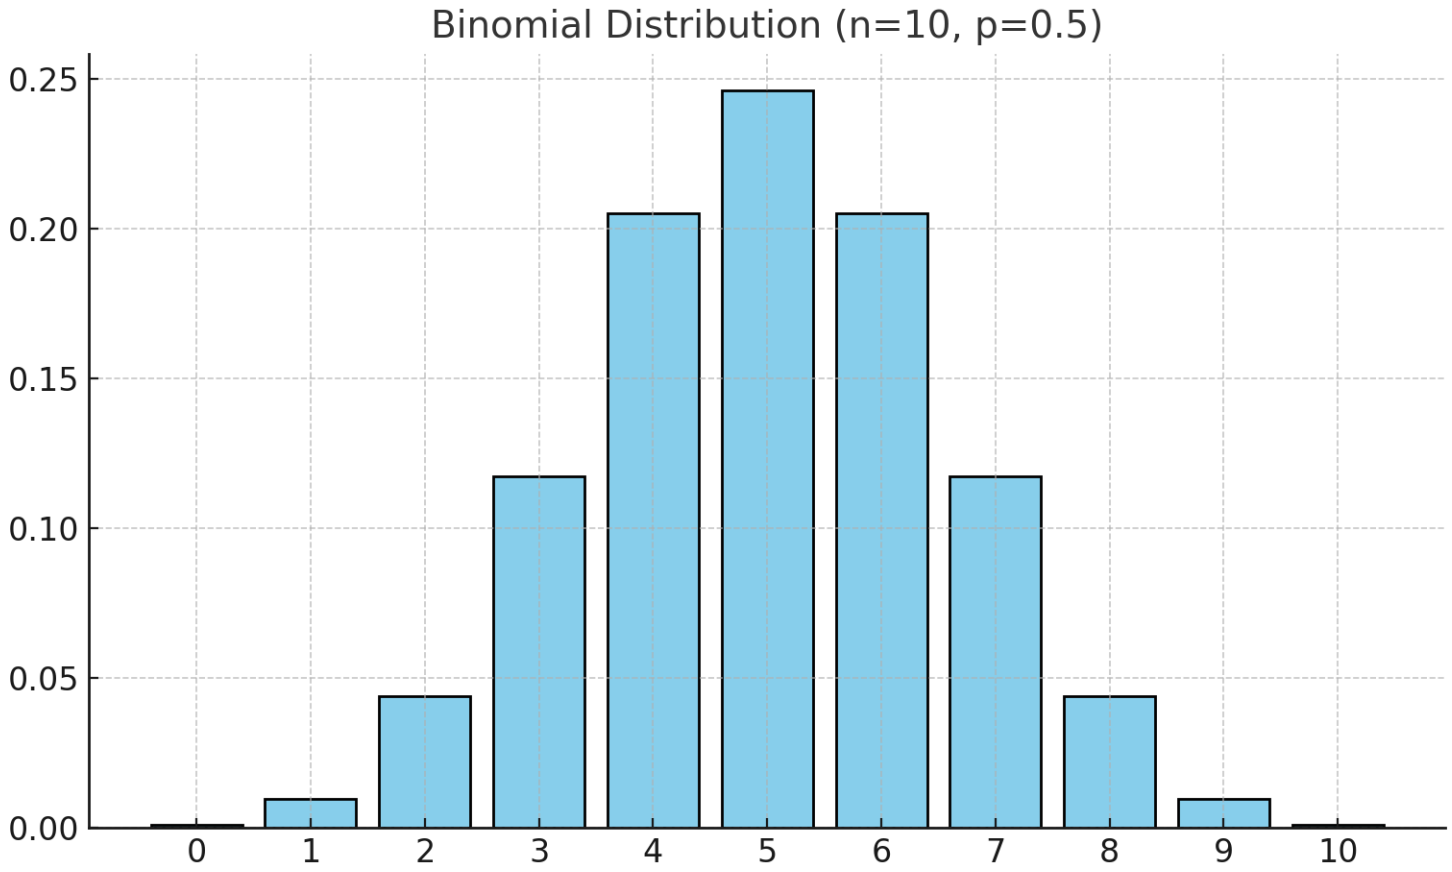
(예)

- 동전 던지기 10번에서 앞면이 6번 나올 확률
- 공장에서 불량품이 정확히 3개 나올 확률
- 시험에서 5문제 중 4개 정답일 확률

👉 이 모델(수식)은 **확률이론이 처음으로 ‘반복되는 우연’을 수학적으로 일반화한 대표적 형태**

이항분포

동전을 10번 던졌을 때, 앞면이 나오는 횟수 분포



- 시행 횟수 n=10
- 성공 확률 p=0.5인 경우의 이항분포 확률질량함수(PMF)를 막대그래프로 나타낸 것

큰 수의 법칙(Law of Large Numbers)

"동전이나 주사위를 반복해서 던질 때, **횟수를 충분히 많이 늘리면**, 실제로 관찰되는 '성공의 비율'은 점점 **이론적인 확률에 가까워짐**

예:

- 동전을 10번 던지면 앞면 비율이 0.3일 수도, 0.8일 수도 있음 (들쭉날쭉)
- 1000번 던지면 대부분 0.5 근처에 몰림
- 10,000번이면 앞면 비율이 0.4나 0.6 되는 건 거의 불가능

👉 즉, **시행 횟수가 커질수록 '우연이 평균에 묶이는' 현상**이 생김

$$\lim_{n\to\infty} \frac{X}{n} = p$$

X = n번 시행 중 '성공한 횟수'

"시행 횟수 n을 충분히 크게 하면, **성공 비율 X/n이** 이론적 확률 p에 점점 가까워진다."

이항분포

이산확률변수 x

확률질량함수 y

→

정규분포

연속확률변수 x

확률밀도함수 y

단계	내용
① 이항분포	반복 시행에서 성공 횟수의 분포
② 큰수의 법칙	시행 횟수가 커질수록 성공비율 X/n이 이론적 확률 p에 수렴
③ 이항분포의 모양	n이 커지면 np를 중심으로 분포가 점차 매끄러운 종 모양에 가까워짐
④ 정규분포로 근사	P=1/2인 이항분포에서 n이 충분히 커질 때 정규분포로 근사할 수 있음을 보임 (수학자 드 무아브르)
⑤정규분포	정규분포 함수식 제시. 가우스 분포(Gaussian distribution)
⑥ 중심극한정리	일반적인 0<p<1로 이항분포를 정규분포로 근사할 수 있음을 보여, 정규분포를 보편적인 분포로 발전시킴 (수학자 라플라스)

중심극한정리(Central Limit Theorm)

"독립이고, 같은 분포를 따르는 확률변수들의 합은, 그 원래 분포가 무엇이든 간에,
시행 횟수가 충분히 커지면 정규분포로 수렴한다."

예1. 쿠키 반죽

쿠키에 초콜릿 칩이 아무렇게나 뿌려져 있다 해도, 여러 덩어리를 모아서 반죽하면 결국 **전체적으로 골고루 섞인 상태**가 됨

👉 처음엔 불균등하고 제각각인 데이터(분포)도, 많이 섞고 합치면 결국 '평균적인 형태(정규분포)'로 감

예2. 여러 가지 요인들이 합쳐진 결과

학생들의 시험 점수를 생각해보기

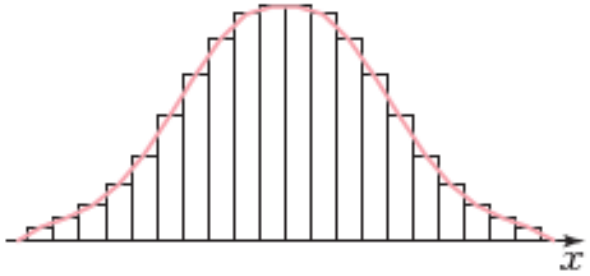
- 시험 점수에는 공부량, 컨디션, 운, 문제 난이도 등 수많은 요인이 영향을 줌.
- 각각의 요인은 제각각 분포를 가질 수 있음 (어떤 건 치우치고, 어떤 건 들쭉날쭉)
- 하지만 이 많은 요인들이 **더해져서 하나의 점수로 나오면** → → 전체 점수 분포는 **정규분포에 가까워짐** (실제 전국 단위 시험 점수 분포)

👉 즉, **많은 독립적인 요인들의 합이 정규분포로 수렴한다**

정규분포



강수량, 키, 몸무게 등과 같은 자연 현상이나 사회 현상을 관찰하여 얻은 자료를 히스토그램으로 그리면 오른쪽 그림과 같이 좌우 대칭인 종 모양의 곡선에 가까워지는 경우가 많다.



🪄 **대부분이 현상이 정규분포라고?! 정규분포는 '마법'??**

정규분포는 인간이 임의로 만들어낸 그래프가 아니라,

👉 수많은 복잡하고 제각각인 우연들이 **모여서 평균화될 때 자연스럽게 나타나는 보편적인 패턴**입니다.

- 동전 수천 번 던지기 /시험 점수 / 키, 체중 같은 생물학적 특징 / 측정 오차 / .....
- 여러 독립 요인의 합 .....

→ 이런 현상들이 **정규분포 곡선으로 자연스럽게 수렴!**

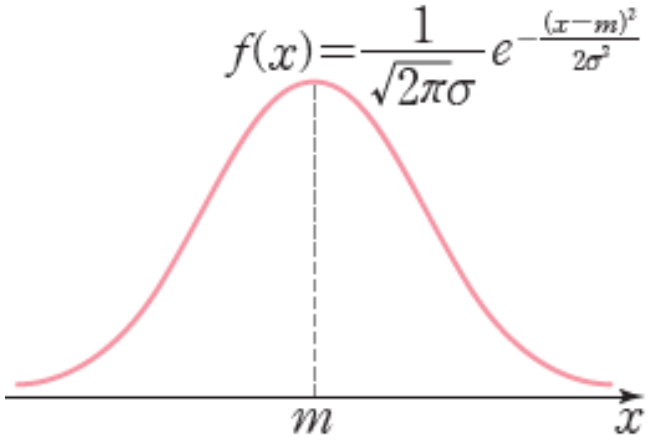
정규분포



연속확률변수 X가 모든 실숫값을 가지고, 그 확률밀도함수 f가

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-m)^2}{2\sigma^2}}\ (x\text{는 모든 실수})$$

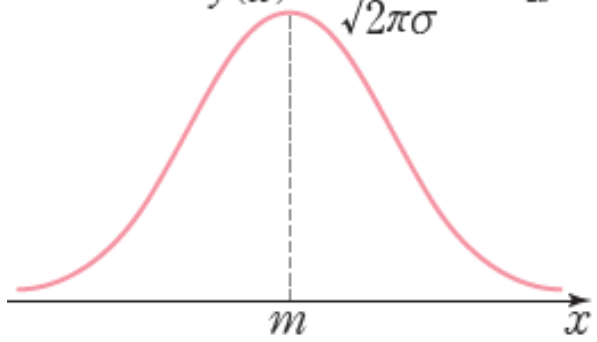
일 때, X의 확률분포를 **정규분포**라 한다.



여기서 e는 그 값이 2.718281…인 무리수이고, 상수 m과 $\sigma\,(\sigma>0)$는 각각 확률변수 X의 평균과 표준편차임이 알려져 있다.

정규분포

$$f(x)=\frac{1}{\sqrt{2\pi}\sigma}e^{-\frac{(x-m)^2}{2\sigma^2}}$$



이처럼 평균이 m이고 표준편차가 σ인 정규분포를 기호로

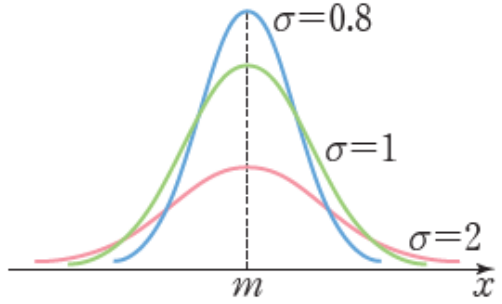
$$\mathrm{N}(m,\ \sigma^2)$$

과 같이 나타낸다. 이때 확률변수 X는 정규분포 $\mathrm{N}(m,\ \sigma^2)$을 따른다고 한다.

정규분포 $\mathrm{N}(m,\ \sigma^2)$의 확률밀도함수의 그래프는 직선 $x=m$에 대하여 대칭이고, 그래프와 x축 사이의 넓이는 1이며 x축을 점근선으로 한다.

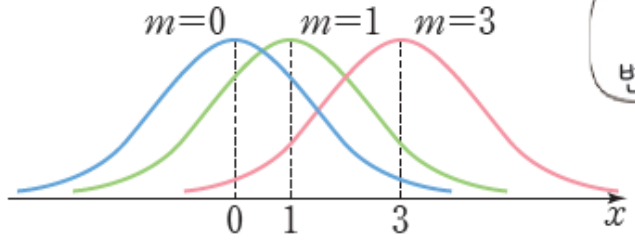


m의 값이 일정하고 σ의 값이 변할 때



[그림 1]

σ의 값이 일정하고 m의 값이 변할 때



[그림 2]



정규분포

정규분포 $\mathrm{N}(m, \sigma^2)$의 확률밀도함수의 그래프의 성질

❶ 직선 $x=m$에 대하여 대칭이고 종 모양의 곡선이다.

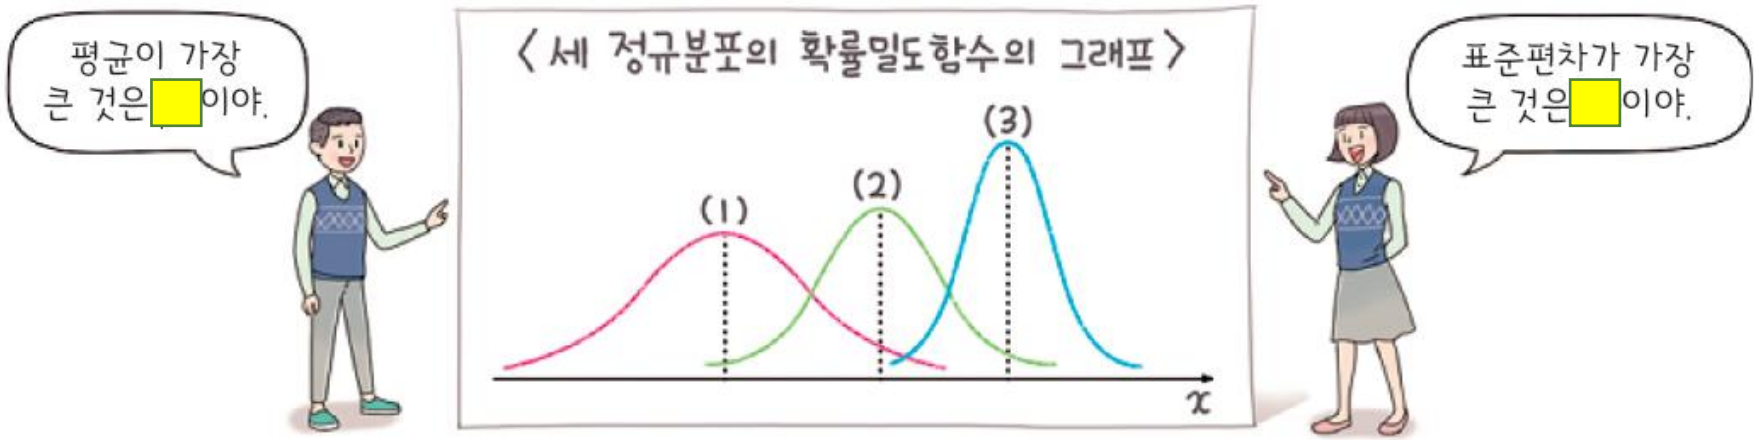
❷ 곡선과 x축 사이의 넓이는 1이다.

❸ x축을 점근선으로 하며, $x=m$일 때 최댓값을 갖는다.

❹ m의 값이 일정할 때, σ의 값이 커지면 곡선은 낮아지면서 양쪽으로 퍼지고, σ의 값이 작아지면 곡선은 높아지면서 뾰족해진다.

❺ σ의 값이 일정할 때, m의 값에 따라 대칭축의 위치는 바뀌지만 곡선의 모양은 같다.

개념 확인

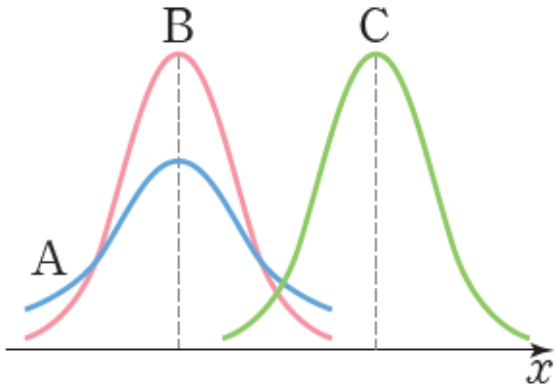


정규분포

개념 확인

오른쪽 그림에서 곡선 A, B, C는 각각 정규분포를 따르는 세 확률변수 X, Y, Z의 확률밀도함수의 그래프이다. X, Y, Z의 평균을 각각 m_1, m_2, m_3이라 하고, 표준편차를 각각 σ_1, σ_2, σ_3이라 할 때, 다음 세 수의 크기를 비교하시오.

(단, 곡선 C는 곡선 B를 평행이동한 것이다.)



(1) m_1, m_2, m_3

(2) σ_1, σ_2, σ_3

[예제1]

실습1의 데이터에 제시된 확률변수 X의 범위는 1부터 100까지입니다.

이 확률변수가 N(50, 25)인 정규분포를 따른다고 할 때,

1) 확률변수 x의 함수값으로  칸을 채우세요.

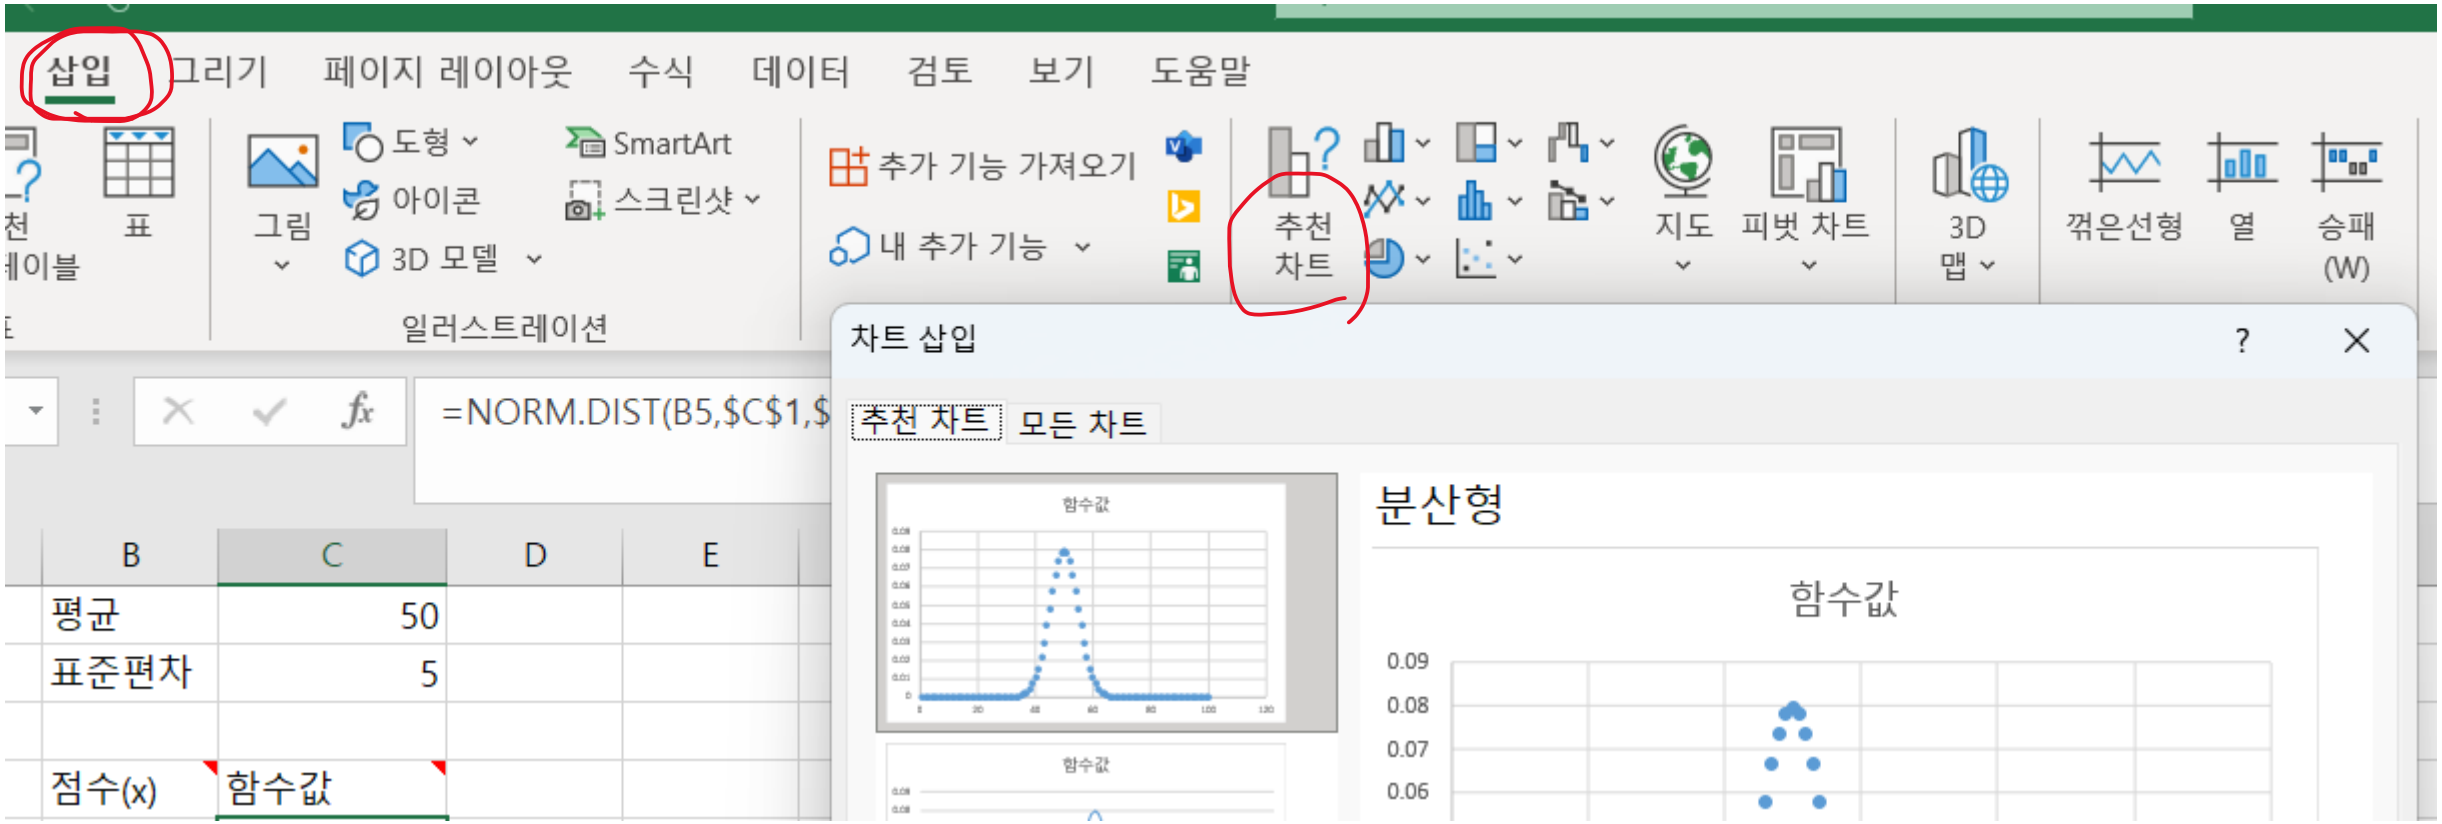
*사용함수 Norm.dist(확률변수, 평균, 표준편차, False)

점수(x)	함수값
1	=NORM.DIST(B5,C1,C2,FALSE)
2	=NORM.DIST(B6,C1,C2,FALSE)
3	=NORM.DIST(B7,C1,C2,FALSE)
4	=NORM.DIST(B8,C1,C2,FALSE)
5	=NORM.DIST(B9,C1,C2,FALSE)
6	=NORM.DIST(B10,C1,C2,FALSE)
7	=NORM.DIST(B11,C1,C2,FALSE)
8	=NORM.DIST(B12,C1,C2,FALSE)
9	=NORM.DIST(B13,C1,C2,FALSE)

[예제1]

2) 정규분포그래프를 그려보세요.

*삽입 탭-추천차트-분산형



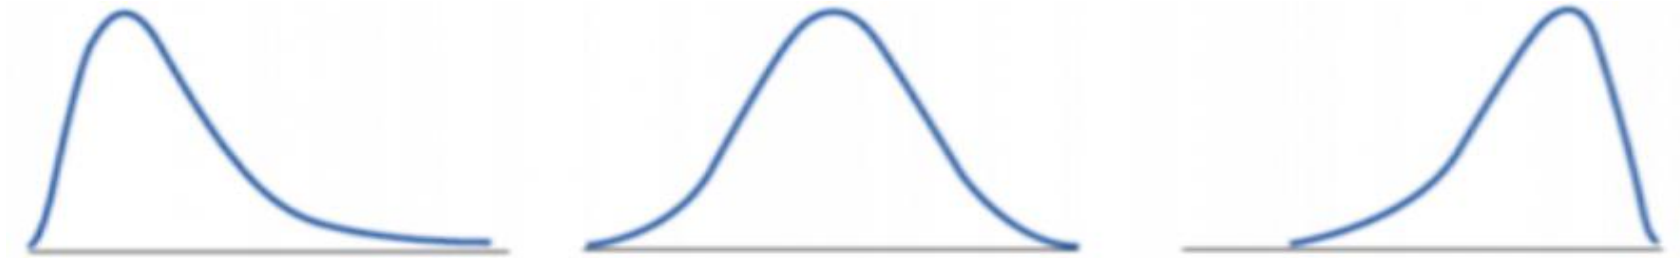
[실습1] & [실습2]

1. N(50, 25)와 N(50,100) 인 정규분포의 그래프를 그려서 평균이 같고 표준편차가 다른 경우 그래프에 어떤 차이가 있는지 확인해보세요.

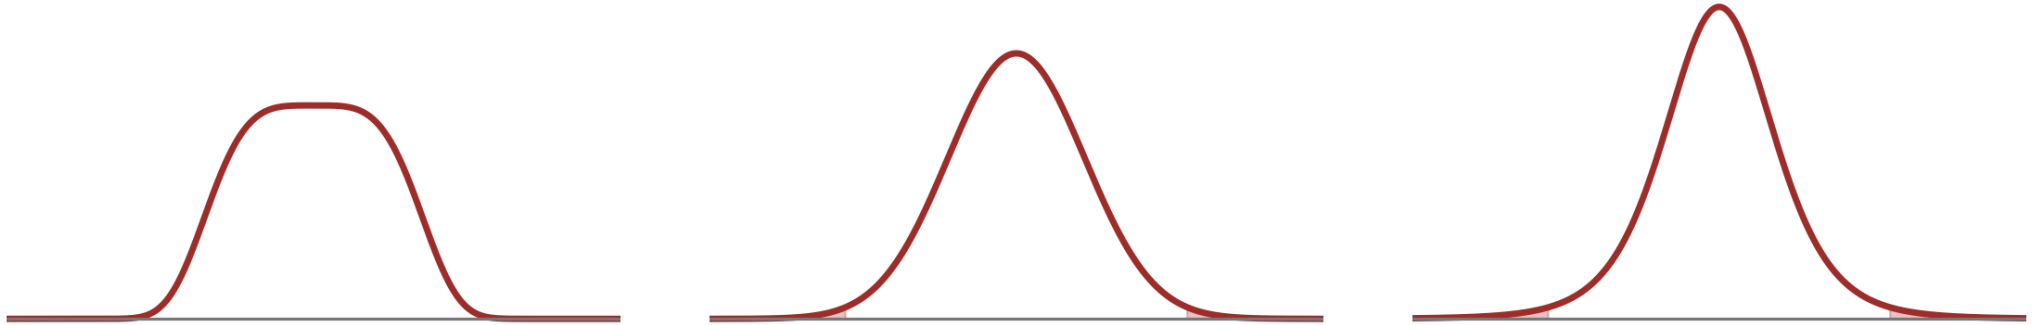
2. N(60, 25)와 N(60,100) 인 정규분포의 그래프를 추가하여 평균과 표준편차가 다른 경우, 그래프에 어떤 차이가 있는지 확인해보세요.

모두 정규분포??

평균을 중심으로 대칭이 아닐 수도 있잖아.



분포 중심이 심하게 뾰족하면(꼬리가 많이 두껍거나 얇으면) 어떡하나...

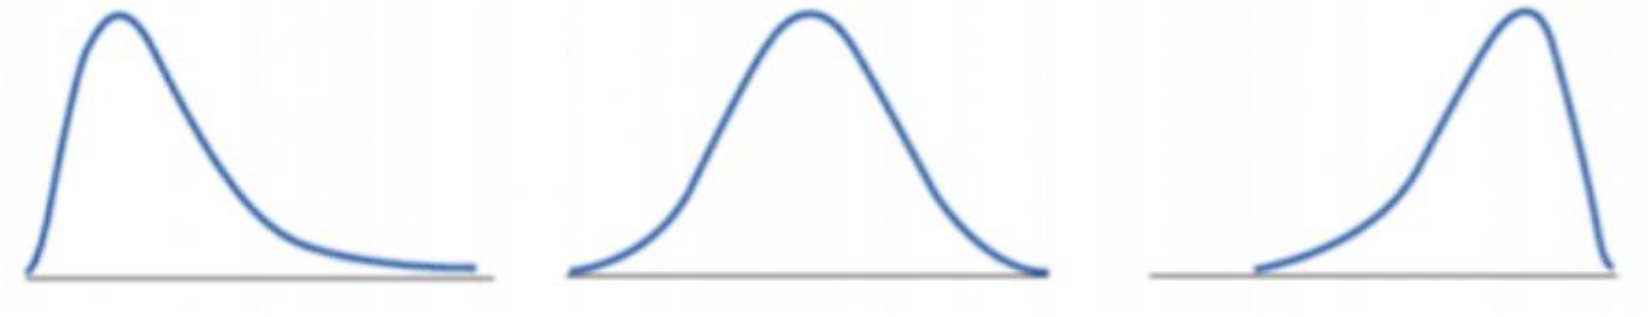


왜도(歪度, Skewness)와 첨도(尖度, kurtosis)

왜도(歪度, Skewness)의 개념

-도수 분포의 집중 형태를 전체적으로 측정한 값

-분포의 비대칭성 정도, 분포가 기울어진 정도와 방향



왜도>0
오른쪽으로 꼬리가 긴 분포

왜도=0
좌우 대칭

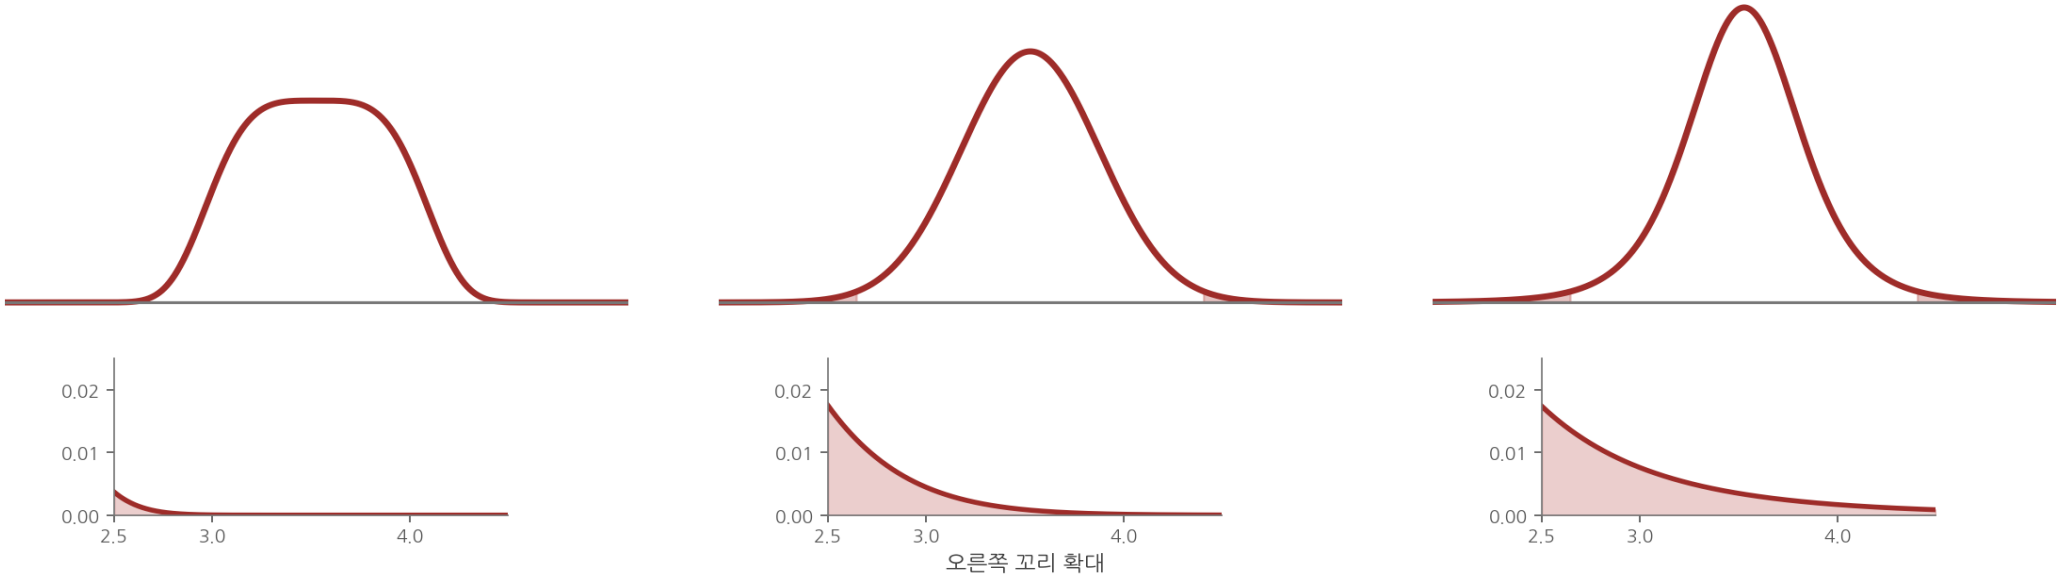
왜도<0
왼쪽으로 꼬리가 긴분포

* 왜도의 절댓값 <2 이면 대칭성 측면에서 정규분포와 유사한 모양"

왜도(歪度, Skewness)와 첨도(尖度, kurtosis)

첨도: 평균에서 떨어진 거리를 표준편차로 나눈 값의 네제곱 평균. '분포의 뾰족한 정도 ' 로 설명하기도 함.

세 분포는 모두 좌우대칭이며 평균 0, 분산 1이다. 가운데 곡선만 정규분포이다.



첨도 < 3

꼬리가 상대적으로 얇은 분포

첨도 ≈ 2.19

첨도 = 3

정규분포

첨도 = 3

첨도 > 3

꼬리가 상대적으로 두꺼운 분포

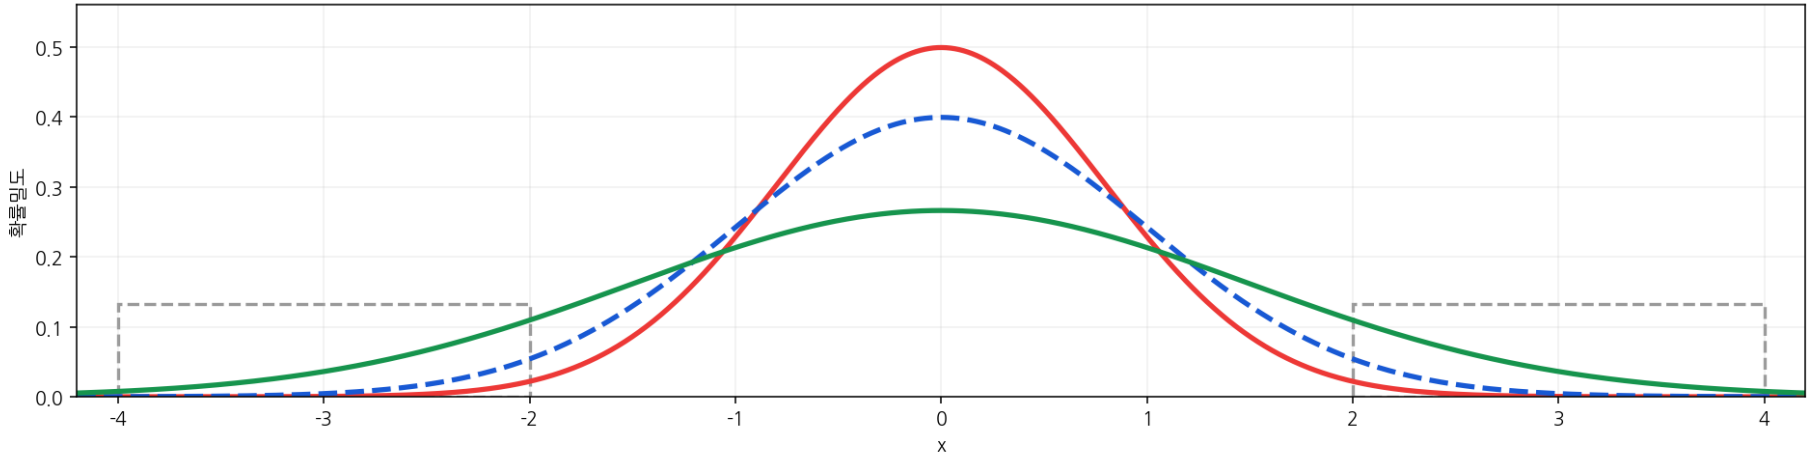
첨도 = 6

정규성 점검의 경험적 참고값: |왜도| < 2, 첨도 < 7

(첨도는 언제나 양수)

참고 분산에 따른 정규분포 모양 비교

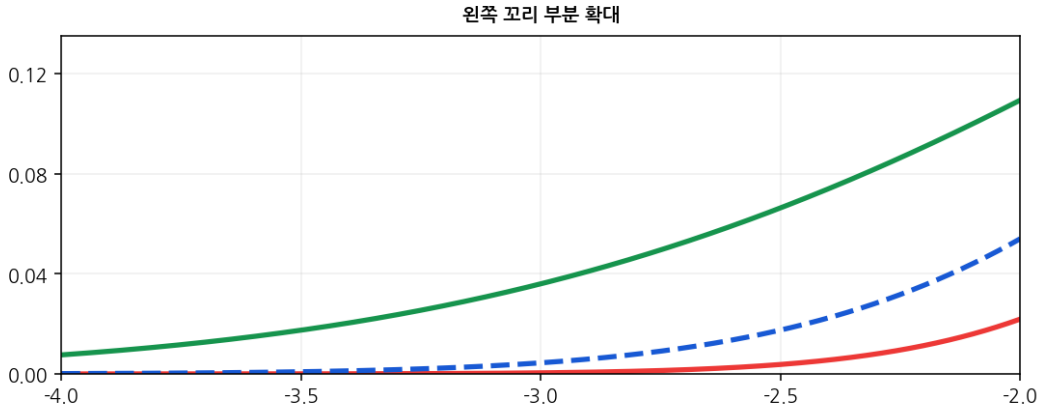
세 분포의 평균은 모두 0이고, 표준편차만 다릅니다.

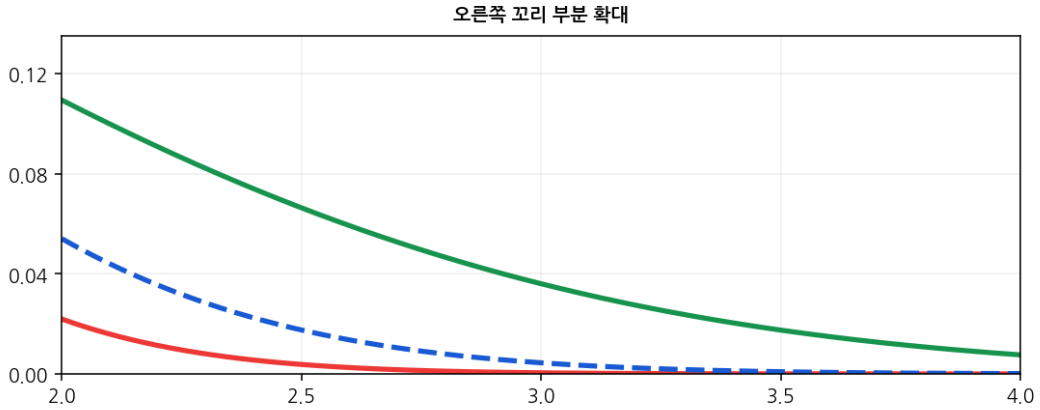


분산이 작은 분포
평균 0 · 분산 0.64

표준정규분포
평균 0 · 분산 1

분산이 큰 분포
평균 0 · 분산 2.25





[데이터를 다룰 때]

데이터를 분석할 때,

다루는 데이터가 정규분포에 해당하는지, 즉 정규성을 만족하는지를 판단해야 한다.

정규성 판별의 가장 기본적인 방법이 왜도와 첨도를 활용하는 방법이다.

|왜도| < 2, 첨도 < 7인지 확인해야 함. 둘 다 만족하면, (변수 1개를 다루는 경우) 정규성 가정을 크게 위배하지 않는다고 본다(West, Finch & Curran, 1995).

'정규성 가정을 만족하는 것을 본다' 고 표현하기로 함. ← 정확히 정규분포임을 증명했다는 의미가 아니라, 분석에 필요한 정규성 가정을 받아들일 수 있다는 의미임.

West, S. G., Finch, J. F., & Curran, P. J. (1995). Structural equation models with nonnormal variables: Problems and remedies. In R. H. Hoyle (Ed.), *Structural equation modeling: Concepts, issues, and applications* (pp. 56–75). Sage.

기술통계학(Discriptive statistics)

✓ 기술통계학

-수집된 데이터를 정리하고 요약하여 그 특성을 파악하는 통계학의 한 분야

-대량의 데이터의 특징을 간결하고 정확하게 표현하는데 중점을 둠

✓ 대표적인 기술통계량

-중심경향성: 데이터의 중심이 어디에 위치하는지 나타내는 통계 척도

예) 평균, 중앙값, 최빈값 등

-산포도: 데이터가 얼마나 퍼져있는지를 나타내는 통계 척도

예) 범위, 분산, 표준편차 등

-데이터의 분포 형태를 설명하는 척도

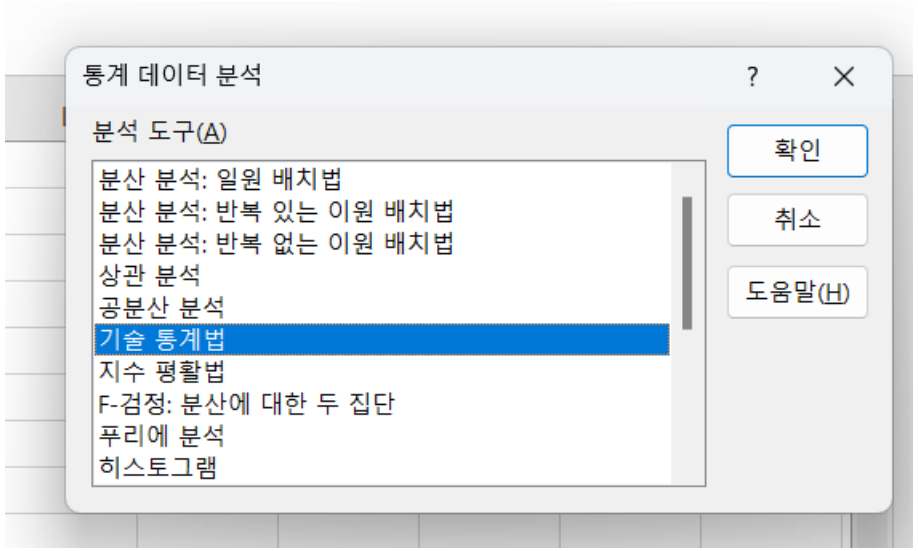
예) 왜도, 첨도

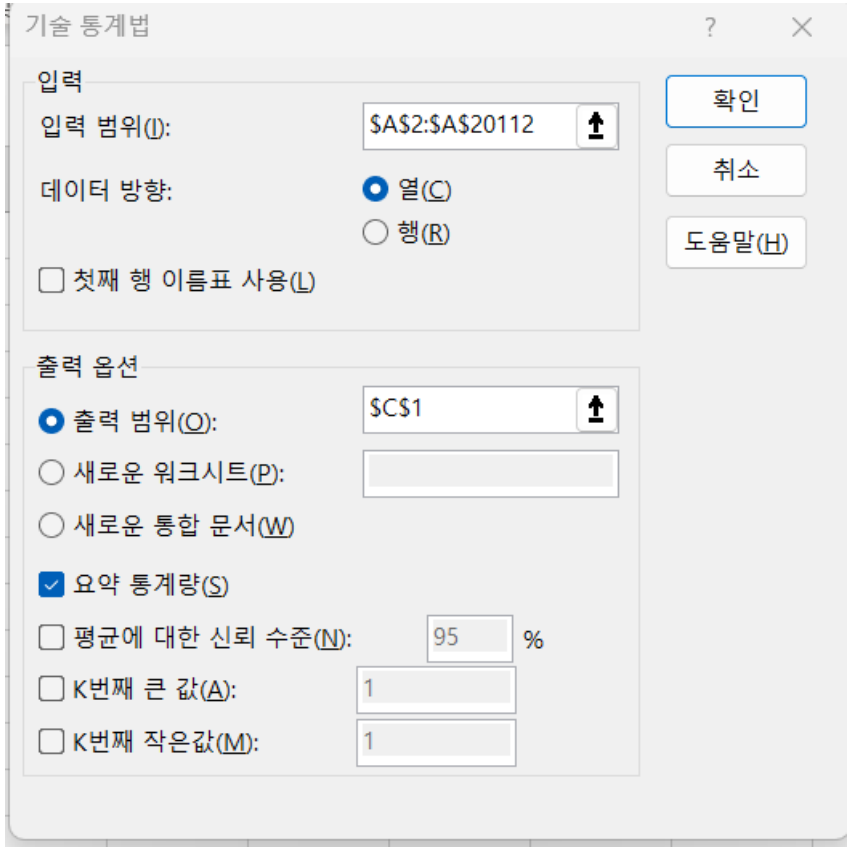
[예제2]

[실습2-1]의 데이터는 교육부에서 공시한 2019년 초등학생 건강검사 표본통계의 키 데이터입니다.

1) 이 데이터의 기술통계량을 구하세요.

*데이터 분석-기술통계법 활용





2) 이 데이터의 왜도와 첨도는 얼마인가요? 이 데이터는 정규성 가정을 만족하나요?

[실습 3]

이 데이터는 [예제2] 데이터에서 중복값을 제거하고 내림차순으로 정리한 데이터입니다. 이 데이터를 사용하여 확률밀도함수값을 구하고, 정규분포 그래프를 그려보세요.

*확률밀도함수값 구하는 엑셀 함수

Norm.dist(확률변수, 평균, 표준편차, false)

*정규분포그래프

삽입 탭-추천차트-분산형

[실습 4] & [실습5]

◆ [실습4]는 교육부에서 공시한 2019년 초등학생 건강검사 표본통계의 몸무게 데이터입니다.

1) 이 데이터의 기술통계량을 구하세요.

2) 이 데이터의 왜도와 첨도는 얼마인가요? 이 데이터는 정규성을 가정을 만족한다고 볼 수 있나요?

◆ [실습5]는 [실습 4]에서 중복값을 제거하고 내림차순으로 정리한 데이터입니다.
이 데이터를 사용하여 확률밀도함수값을 구하고, 정규분포 그래프를 그려보세요.