

자료의 정리와 요약 : 통계량

자료출처: 기초통계학(오만숙 저, 2026, 경문사 출판)

통계분석 단계

Step 1 자료의 수집

Step 2 자료의 정리와 요약 (descriptive statistics)

Step 3 자료분석

Step 4 결과 해석

자료를 수집한 다음, 분석 전에 데이터의 전체적인 상태가 잘 드러나도록 정리하고 요약하는 단계

자료의 시각적 정리

범주형 자료의 정리:

1. 도수분포표
2. 막대그림(히스토그램)

양적 자료의 정리:

1. 도수분포표
2. 막대그림(히스토그램)
3. 줄기잎그림

2.4 자료의 수치적 요약 : 통계량

기초통계학 강의

- A반 60명 새로운 교수법
- B반 70명 기존 교수법

- 학기말 시험 성적 비교

1. 60명과 70명의 성적을 죽 늘어놓고 비교? Nop!!
2. 두 반의 도수분포표/히스토그램 비교? Not bad, but not good either.
3. 두 반의 평균을 비교 (A반 평균 85, B반 평균 75)? Much better. **Simple and clear!**

2.4 자료의 수치적 요약 : 통계량

통계량(statistics)

표본의 관심 있는 특징을 측정(계량)하기 위하여 식(함수)을 적용하여 관측치를 요약한 것

-예: 평균 $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$

관측치의 합 $S = \sum_{i=1}^n X_i$

상수 a 보다 큰 관측치의 개수 $N = \# \text{ of } X_i > a$

관측치의 최대값 $X_{\max} = \max\{X_1, \dots, X_n\}$

2.4.1 위치 통계량

위치 통계량(location parameter)

-자료의 중심이 어디에 위치하는지를 측정하는 통계량


-대표적 위치 통계량: **평균(mean), 중앙값(median), 최빈값(mode)**

2.4.1 위치 통계량 : 평균

자료의 중심을 나타내는 위치 통계량.


평균은 관측치의 무게 중심

- 관측치 (1,1,2,4,7,8,10)
- 시이소를 만들자 : 어디에 고정대를 놓아야 균형을 유지할까?



2.4.1 위치 통계량 : 평균

- 관측치 (1,1,2,4,7,8,10) → 관측치 (1,1,2,4,7,8,17)



2.4.1 위치 통계량 : 평균


- 평균의 관측치의 무게 중심
- 평균은 이상점(outlier)의 영향을 많이 받는다
- 이상점: 다른 값들에 비하여 지나치게 크거나 작은 값
- 예: 한국직장인의 월평균 임금 조사, 30명 표본, 삼성전자 CEO가 표본 중 1명이라면
=> 표본의 평균이 과도하게 커짐

2.4.1 위치 통계량 : 중앙값(median)

- 중앙값은 관측치를 크기 순으로 정렬한 뒤 반으로 나누는 기준값
- 중앙값은 히스토그램의 면적을 양쪽으로 반씩 나누는 값이다.
- 이상점의 영향을 덜 받는다. 이상점에 대한 관용성(robustness)
- 예: 관측치 (1,1,2,4,7,8,10) 의 중앙값 = 4
관측치 (1,1,2,4,7,8,17) 의 중앙값 = 4

2.5.1 위치 통계량 : 중앙값

- 관측치 (1,1,2,4,7,8,**10**)
- 관측치 (1,1,2,4,7,8,**17**)



2.4.1 위치 통계량 : 평균 vs 중앙값




그림 2.13 자료의 히스토그램과 평균(blue line), 중앙값(red line).

-대칭분포 : **평균**=**중앙값**

-오른쪽 긴꼬리 : **평균** > **중앙값**

-왼쪽 긴꼬리 : **평균** < **중앙값**

2.4.1 위치 통계량 : 최빈값(mode)

최빈값: 가장 빈번이 관측되는 관측치

- (1,1,2,4,7,8,10) -> 최빈값 = 1

- 보통 많은 수의 가능한 값을 가진 양적 자료에서 최빈값은 위치통계량으로 의미 약함

-예: 서울시 구 인구 최빈값??

관측치가 모두 다르기 때문에 최빈값이 자료의 중심 나타내기 어려움.

12.64 15.18 22.91 23.36 30.37 31.05 31.45 33.58 34.66 35.30

36.86 37.32 39.79 39.92 40.64 42.60 43.14 44.15 46.04 48.19

50.24 53.59 54.32 59.43 67.77

2.4.1 위치 통계량 : 최빈구간

-자료를 구간으로 나눈 후
최빈구간 ? 30~40만

<표 2.4.1> 서울시 구 인구의 구간별 도수

구간	도수
10 ~ 20	2
20 ~ 30	2
30 ~ 40	10
40 ~ 50	6
50 ~ 60	4
60 ~ 70	1

2.4.1 위치 통계량 : 최빈범주

-범주형 자료에서 최빈범주?

- 통증자료:

최빈범주=1(통증거의없음)


<표 2.3.2> 통증의 강도별 도수

통증의 강도	도수	상대도수(%)
1	9	30
2	6	20
3	7	23
4	5	17
5	3	10
총합	30	100

2.4.1 최빈 구간은 여럿일 수도 있다

-잔디의 CO2 흡수율

- **쌍봉(bimodal)** 모양 : 35 근방에서 큰 봉우리 & 15 근방에서 또 다른 봉우리
- 보통 서로 다른 특성을 가진 두 그룹이 존재함을 의미
- 잔디를 채취한 장소(퀘벡, 미시시피) 에 따라 다른 CO2 흡수율을 가짐




2.5.2 퍼짐성 통계량 (dispersion statistic)

-여성복 제조회사 A 와 B


- A: 타우라 부족 여성을 타겟 소비자 B: 마우라 부족 여성을 타겟 소비자
- 타우라와 마우라 부족의 여성 **평균 신장은 똑같이 158cm**
- **A, B: 156~160 cm 키의 여성에게 알맞은 치수의 옷을 제작**
- A는 타우라 여성에게, B는 마우라 여성에게 판매
- 다른 판매조건이 모두 비슷,
BUT A회사 제품은 잘 팔리는 반면 **B회사 제품은 예상보다 판매가 부진**

2.5.2 퍼짐성 통계량 (dispersion statistic)

- 두 부족에서 각각 1,000명, 여성 표본을 추출하여 키 측정



A: 타우라 부족



B: 마우라 부족

이 두 그래프를 비교하여
해석하면?

2.5.2 퍼짐성 통계량 : 분산(Variance)

편차(deviation) = $D_i = X_i - \bar{X}$

- 편차가 큰 관측치가 많다 => 퍼짐성이 크다
- 편차는 n 개 존재, 이들을 요약하는 통계량?
- How about 편차의 평균? Noh! 왜냐하면 항상 $\sum_{i=1}^n D_i = 0$
- 편차제곱의 평균?

분산(Variance, Var) : $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$

- 그런데 왜 n 이 아닌 n - 1로 나누지? 편차는 총 n 개이지만 제약조건 $\sum_{i=1}^n D_i = 0$ 때문에

*분산의 자유도는 n - 1

2.5.2 퍼짐성 통계량 : 분산

자유도 (degrees of freedom) 란?

- 통계량의 자유도: 대략적으로 그 통계량이 몇 개의 독립적인 정보로부터 계산된 것인가를 나타내는 수치
- 분산: 독립적인 n 개의 관측치로부터 계산된 편차를 이용하였지만
편차 합이 0이라는 제약조건 때문에 **사실은 $n - 1$ 개의 독립적 정보를 요약한 통계량이다.** **$n - 1$ 개의 편차만 알면 편차 합이 0이라는 제약조건으로부터 나머지 하나를 알아낼 수 있기 때문이다.**
- 따라서 **분산의 자유도는 $n - 1$**

2.5.2 퍼짐성 통계량 : 분산

- 퍼짐성이 크면 => 분산이 크다

분산은 퍼짐성 측도로 좋은 성질을 많이 가짐.

- 그런데, 잠깐!

타우라 vs 마우라

타우라 여성 키의 분산은 1 cm^2 , 마우라 여성 키의 분산은 16 cm^2

2.5.2 퍼짐성 통계량 : 표준편차

- **앗!!** 분산의 단위가 cm^2 ??
- 관측치와 평균의 단위는 cm
- 분산의 단위가 다르기 때문에 평균 또는 관측치와 + 또는 - 등 계산 불가능
- 해석이 어려운 경우 발생

- 분산에 제곱근을 취하면?


표준편차(standard deviation, SD) $s = \sqrt{Var} = \sqrt{s^2}$

2.5.2 퍼짐성 통계량 : 표준편차

- 분산은 편차제곱 “평균” , 표준편차는 분산의 제곱근
- 분산, 표준편차도 이상점의 영향을 받음

2.5.2 퍼짐성 통계량 : 사분위범위


- 4분위범위(Inter-Quartile Range, IQR)
- Q1(제1사분위수) 와 Q3(제3사분위수) 의 거리 - $IQR = Q3 - Q1$



- 자료의 퍼짐성이 크면 => Q1과 Q3의 차이가 크다 => IQR 이 크다
- 분위수로부터 계산되므로 이상점에 덜 민감

(참고) 양적 자료의 정리 : 상자그림 (box plot)

Group 1	Group 2
71	61
81	73
59	56
60	65
63	60
76	49
58	51
69	52
62	78
54	
31	



2.5.3 적절한 통계량의 사용

평균, 표준편차, 분산 :

- 통계분석에 필요한 **수리적 계산이 편함**
- **가장 널리 사용됨**
- 분포가 대략 대칭적 일 때 적절 (이상점에 민감하므로)

중앙값, IQR

- 분포가 심하게 비대칭적 일 때 적절 (이상점에 덜 민감하므로)
- **수리적 계산이 어려움**

일반적으로, 비대칭 분포의 경우 자료의 변환(transformation)을 통하여 대칭에 가깝게 만든 다음 평균, 분산, 표준편차를 이용할 것을 권장한다.

수업참여 과제(10/5)

09 다음 물음에 답하라.

- (1) 자료 3 3 3 4 4 4 4 5 5 5의 평균과 중앙값을 구하라.
- (2) 위 자료의 각 관측치에 2를 더한 5 5 5 6 6 6 6 7 7 7의 평균과 중앙값을 구하라.
- (3) (2)번 자료의 평균과 (1)번 자료의 평균과의 관계는?
- (4) (2)번 자료의 중앙값과 (1)번 자료의 중앙값과의 관계는?

10 자료가 1, 1, 1, 1, 2, 2, 2, 3, 3, 3, 3, 3, 3, 3, 4, 4, 4, 5, 6, 6, 7, 7, 7, 7, 7, 7, 8, 8, 8, 9, 9, 9, 9, 9, 9, 100으로 주어졌다. 살펴보니 최대값 100은 10을 잘못 기록한 것이 발견되어 100을 10으로 바꾸었다. 다음 중 수정 이후에 값이 달라지는 통계량을 모두 골라라.

- | | |
|---------|-------|
| ① 평균 | ② 중앙값 |
| ③ 사분위범위 | ④ 최빈값 |

11 다음 평균에 대한 기술 중 참(TRUE)인 것을 모두 골라라.

- ① 평균을 계산할 때는 모든 자료 값을 이용한다.
- ② 평균은 이상점(outlier, extreme value)의 영향을 받는다.
- ③ 자료의 약 절반은 평균보다 크다.

12 다음 중 자료의 퍼짐성(dispersion)을 요약하는 통계량이 아닌 것은?

- | | |
|---------|-------------|
| ① 사분위범위 | ② 분산 |
| ③ 표준편차 | ④ 보기 중 답 없음 |