10주차

표본조사, 표본 분포, 신뢰구간

2026-11-02

일부 그림출처: 공돌이의 수학정리노트, 유튜브
일부 자료출처: 천재교육 <확률과통계(류희찬 저)>

학습할 내용

- 표본조사
- 모집단의 분포 vs 표본 분포
- 신뢰도, 신뢰구간

전수조사와 표본조사

* 어느 양식장에서 키우고 있는 물고기의 무게를 조사하려고 한다. 알맞은 조사 방법은?



조사 대상이 되는 집단 전체를 조사하는 것　　조사 대상 중에서 일부분만 택하여 조사하는 것

전수조사

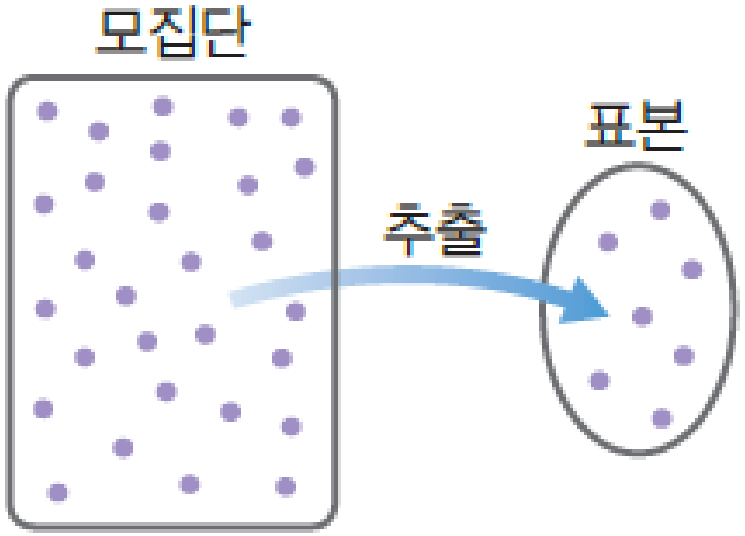
- 자료의 특성을 정확히 알 수 있다.
- 많은 시간과 비용이 필요하다.



표본조사

- 자료의 특성을 근사적으로 알 수 있다.
- 시간과 비용을 절약해야 하는 경우에 사용한다.

모집단과 표본



*통계 조사에서 조사의 대상이 되는 집단 전체를 **모집단(population),** 모집단에서 뽑은 일부분을 **표본(sample)**라고 한다. 표본에 포함된 대상의 개수를 **표본의 크기(sample size)**라 하고, 모집단에서 표본을 뽑는 것을 **추출(sampling)**이라 한다.

*샘플링 시 주의점!
-꼭 임의추출(random sampling)하기!!

임의추출이란?

표본조사 (Sampling)

전수조사

- 전수조사(총조사, 센서스): 모집단 모두를 조사
- 예: 기숙사의 거주자 모두에게 코로나 검사를 실시
- 인구센서스: 정부 주도하에 모든 국민 조사

한국은 정책수립과 각종 통계작성의 기초자료로 활용되는 기본통계를 작성하기 위하여 전국민을 대상으로 하는 인구·주택·사업체 등에 관한 인구 센서스를 통계청에서 5년마다 실시하고 있다.

표본조사 (Sampling)

표본조사

- 전체 대상의 일부를 추출하여 조사하는 것을 표본조사(sampling)라 한다.
- 전체 대상 집단을 모집단(population)이라 한다.

> 예: 홍길동(씨)와 허균(씨)는 차기 대통령 후보로 출마

- Q: 홍길동과 허균 후보의 실제 선거에서의 득표율은 얼마일까?
- 모집단: 한국의 유권자 수 (2021년 1월 기준 약 4200만 명)
- 소규모 유권자(표본, sample)를 추출하여 지지도를 조사하고,
  이를 바탕으로 실제 선거에서의 득표율을 추정하고자 한다.

표본조사 (Sampling)

표본의 대표성

좋은 표본 = 전체 모집단의 구성원을 골고루 대표하는 표본

- 좋은 자료를 얻기 위한 기본 원칙은 편이(bias)가 없는 표본을 뽑는 것
- 표본의 대표성: 치우침 없이 모집단의 모든 구성원을 잘 대표하는 표본

핵심 질문: 어떻게 하면 대표성 있는 좋은 표본을 뽑을 수 있을까?

표본조사 : 1936년 미국 대통령 선거 예

루즈벨트 vs 랜든

- **다이제스트(**Literary Digest) 잡지사:
  - -표본크기 : 240만 명
  - 조사결과 : 랜든 (57%) , 루즈벨트(43%)
- **갤럽(Gallup)**
  - 표본크기 : 5만명
  - 결과 : 랜든(44%), 루즈벨트 (56%)
- **실제 선거** : 루즈벨트 62%

표본조사 : 1936년 미국 대통령 선거 예

다이제스트의 표본조사에서 무엇이 잘못된 것일까?

- **다이제스트 표본조사**
  - 전화번호부와 차량등록부에 수록된 명단 중 1000만 명을 랜덤추출
  - 1000만 명에게 설문지 우편 송부
  - 그 중 240만 명이 설문지에 답변
  - 240만 명 표본 중 43% 루즈벨트를 지지

표본조사 : 1936년 미국 대통령 선거 예

다이제스트 표본에 존재하는 두 가지 심각한 편이

(1) 선택편이 (selection bias)

: 표본을 뽑는 과정에서 특정 집단이 체계적으로 더 많이 포함되거나 제외되어 표본이 모집단을 제대로 대표하지 못하는 현상

- 전화번호부와 차량등록부에 수록된 명단 이용

표본조사 : 1936년 미국 대통령 선거 예

다이제스트 표본에 존재하는 두 가지 심각한 편이

(2) 무응답편이(non-response bias)

: 표본으로 선택된 사람들 중 일부가 응답하지 않고, 그 응답하지 않은 사람들의 특성이 응답한 사람들과 체계적으로 달라서 조사 결과가 왜곡되는 현상

- 1000만 명 중 응답한 유권자가 단지 240만명, 전체의 24%
- 다이제스트는 760만명, **무려 76%의 무응답자를 표본에서 배제**
- **표본의 대표성 상실**

표본조사 (Sampling)

Q: 어떻게 하면 대표성 있는 좋은 표본을 뽑을 수 있을까?

(1) 단순랜덤추출(simple random sampling)

- 모집단의 모든 구성원이 표본에 뽑힐 확률이 동일하도록 랜덤표본을 추출한다.
- 구조적 편이(Structural bias)를 방지한다.
- 4200만 유권자 중에서 1000명을 단순랜덤추출하려면?

무작위(random)는 “아무렇게나”가 아니라, 모두에게 같은 기회를 주는 절차입니다.

표본조사 (Sampling)

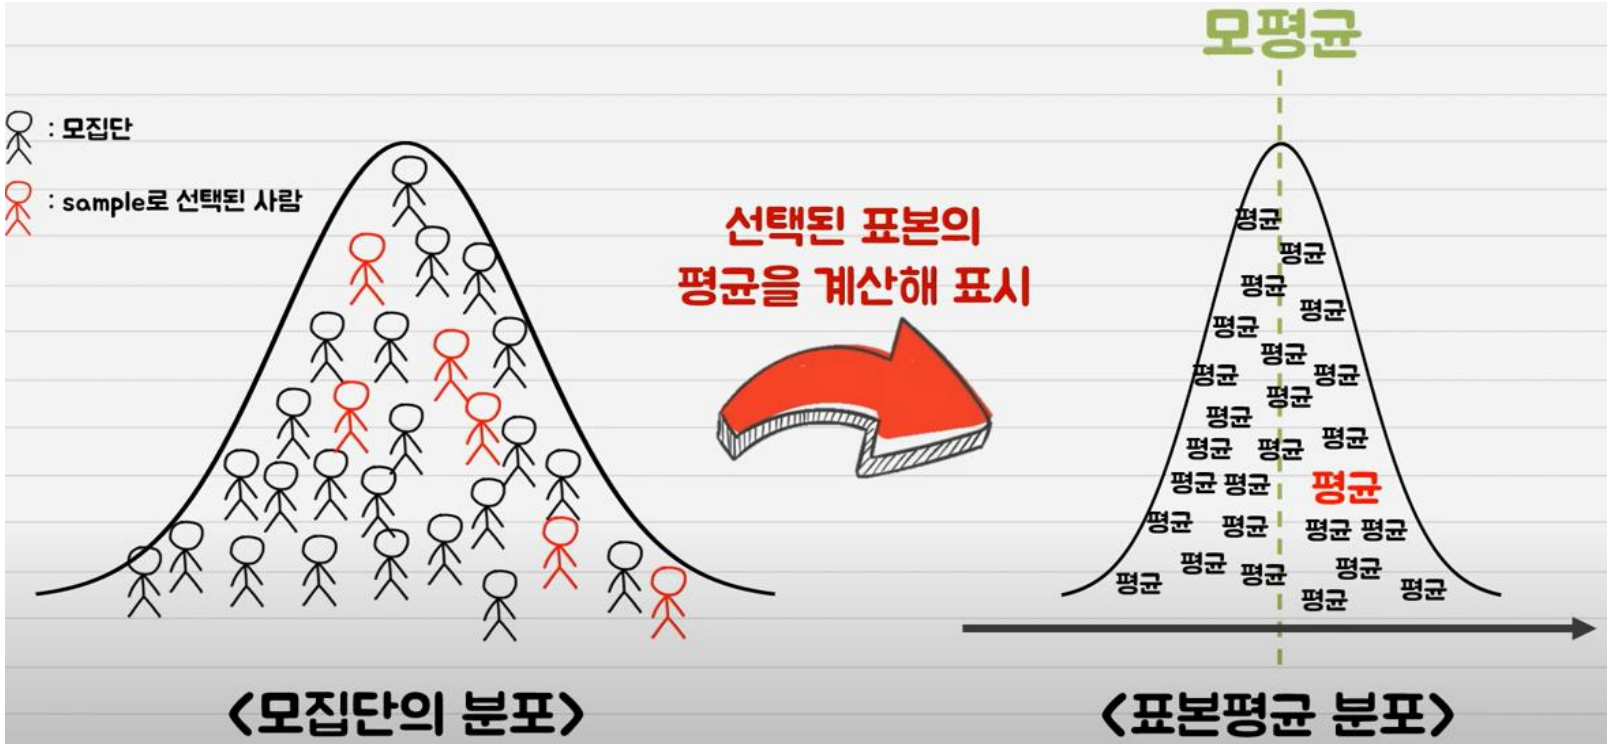
Q: 어떻게 하면 대표성 있는 좋은 표본을 뽑을 수 있을까?

(2) 적절한 크기의 표본

- 랜덤추출에도 오차가 있다.
- 홍길동과 허균의 지지도가 실제로는 1:1이라고 하자.
- 10명의 랜덤표본: 홍길동 지지자가 7명(70%)일 가능성은 10% 이상
- 1000명의 랜덤표본: 홍길동 지지자가 700명(70%)에 가까울 가능성은 거의 0
- 표본크기가 클수록 표본오차는 작아진다.
- 비용과 오차를 고려하여 적절한 표본크기를 결정한다.

모집단의 분포 vs 표본 분포

모집단의 분포 vs 표본평균의 분포



- 표본평균이 이룬 정규분포의 중앙값(=평균)이 모평균과 일치한다! 왜.....?
- 그렇다면 분산은...? 샘플링한 표본평균의 분포는 모평균을 중심으로 모이는 경향이 있음.
- 결과적으로,

모집단의 분포가 정규분포 $N(m, \sigma^2)$라면, 표본 크기가 n인 표본평균의 분포는 .....?

표본평균$\bar{X}$ 의 기댓값과 분산

$E(X_i) = \mu$, $Var(X_i) = \sigma^2$일 때 $\bar{X}$의 기대치와 분산을 구해보자.

- 기댓값 : $E(\bar{X}) = \mu$ (표본평균들의 평균은 실제 모평균과 같다)
- 분산: $Var(\bar{X}) = \frac{\sigma^2}{n}$
- (표본 크기 n이 커질수록 표본평균의 흩어짐은 줄어든다)
- 표준오차(Standard Error): $SE = \sigma/\sqrt{n}$

$\bar{X}$ 의 표본분포

$E(X_i) = \mu$, $Var(X_i) = \sigma^2$일 때 $\bar{X}$의 기대치와 분산을 구해보자.

$$E(\bar{X}) = E\left(\frac{1}{n}X_1 + \ldots + \frac{1}{n}X_n\right) = \frac{1}{n}E(X_1) + \cdots + \frac{1}{n}E(X_n) = \frac{1}{n}\mu + \ldots + \frac{1}{n}\mu = \mu$$

$$Var(\bar{X}) = Var\left(\frac{1}{n}X_1 + \cdots + \frac{1}{n}X_n\right) = \frac{1}{n^2}Var(X_1) + \cdots + \frac{1}{n^2}Var(X_n)$$

$$= \frac{1}{n^2}n\sigma^2 = \frac{\sigma^2}{n}$$

=>따라서 $\bar{X}$의 표준편차 SE = $\sigma/\sqrt{n}$

$\bar{X}$ 의 표본분포

예제 1) 어떤 도시의 모든 주거지 조사

세대당 주거 면적의 평균이 $70m^2$, 표준편차가 $15m^2$일 때, 이 도시에서 25개의 주거지를 랜덤 추출한 주거지의 평균면적의 기대치 $E(\bar{X})$는 $70m^2$, 표준오차 $SE(\bar{X}) =$ _____

모집단이 정규분포 이므로,

$$\bar{X} \sim N(\ _____,\ _____\ )$$

$\bar{X}$ 의 표본분포

예제 2) 학생들의 수학점수 $X \sim N(60, 20^2)$ 일 때, n=4, 16, 50에 대하여 표본평균 $\bar{X}$가 따르는 분포는?

풀이) 모집단이 정규분포 이므로 $\bar{X} \sim N(\mu, \sigma^2/n)$

n =4일 때, SE = _____ → $\bar{X} \sim N($ ____, ____ $)$

n =16일 때, SE = _____ → $\bar{X} \sim N($ ____, ____ $)$

n =50일 때, SE = _____ → $\bar{X} \sim N($ ____, ____ $)$

신뢰도 & 신뢰구간

하지만, 표본은 표본일 뿐! 우리가 모집단의 분포를 모르면

어떻게 해야하나. 표본은 표본일 뿐인데.....!

예제 3. 주거 면적의 모평균 추정 (예제 1과 비교해보기)

어느 도시의 세대당 주거 면적은 정규분포를 따른다.

모표준편차는 15 m^2로 알려져 있지만, 모평균 μ는 알지 못한다.

주거지 25개를 무작위로 추출했더니 표본평균은 72 m^2였다.

이 도시의 세대당 평균 주거 면적 μ의 95% 신뢰구간을 구하시오.

주어진 값: $n = 25$, $\bar{x} = 72\ m^2$, $\sigma = 15\ m^2$

예제 2 수학 점수의 모평균 추정 (예제4와 비교해보기)

학생들의 수학 점수는 정규분포를 따른다고 하자.

모표준편차는 20점으로 알려져 있고, 모평균 μ는 알지 못한다.

각각 독립적으로 조사한 표본의 결과는 다음과 같다.

표본 크기 n	**4명**	**16명**	**50명**
표본평균 $\bar{x}$	64점	62점	61점

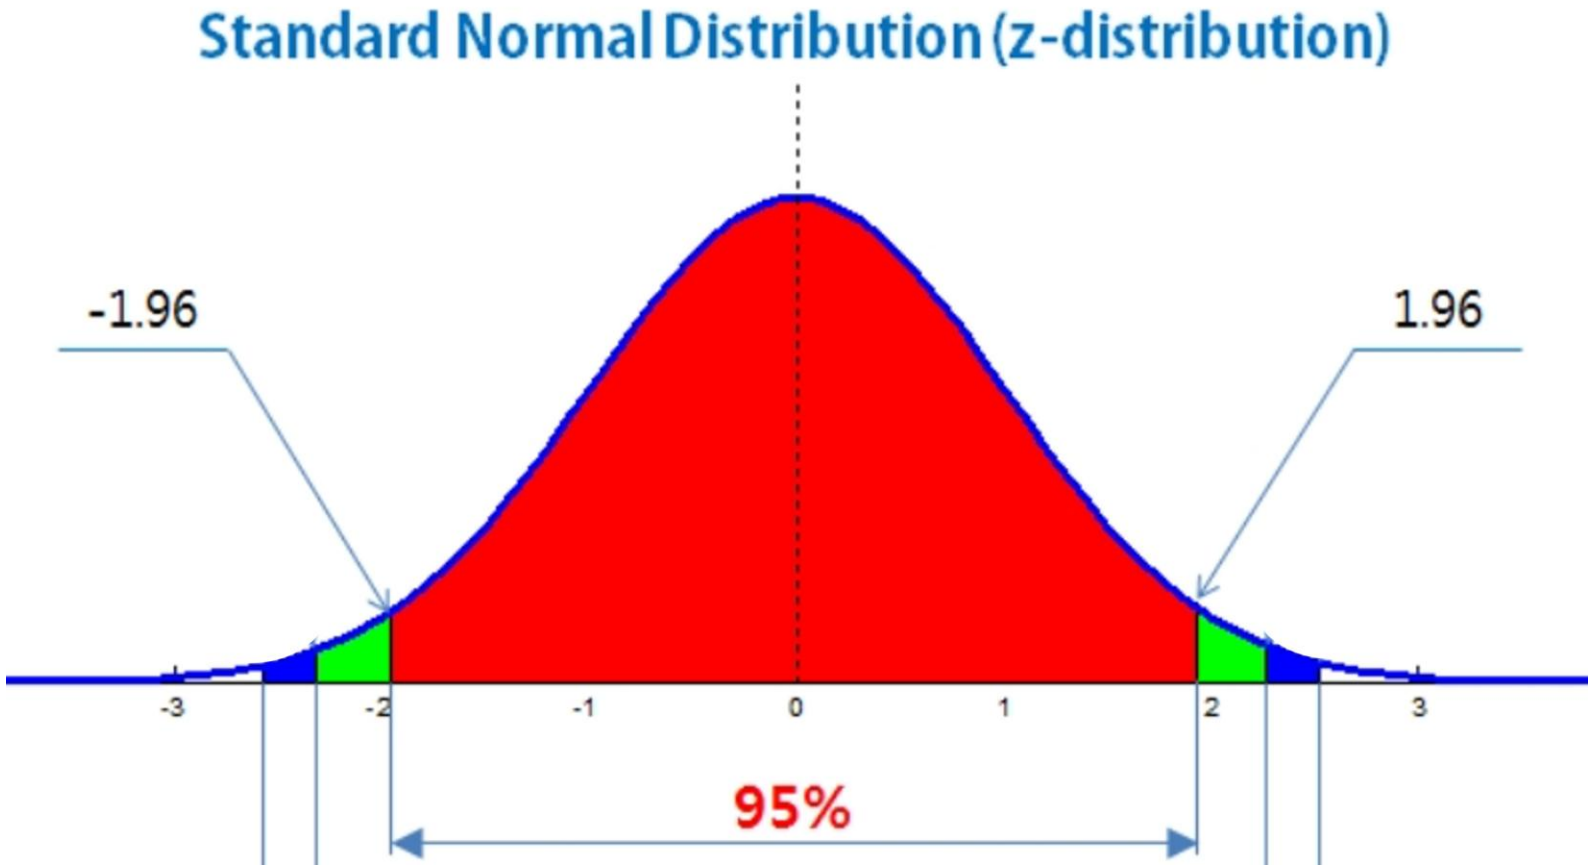
각 조사에서 μ의 95% 신뢰구간을 구하고 폭을 비교하시오.

신뢰도 & 신뢰구간

우리는 표본평균의 분포가 정규분포를 따른다는 점을 활용하여 모집단의 분포를 추정하게 된다.

하지만, 표본은 표본일 뿐. 불확실성과 확실성을 함께 표현하는 방법으로써, '신뢰도'과 '신뢰구간'이라는 개념을 도입한다.

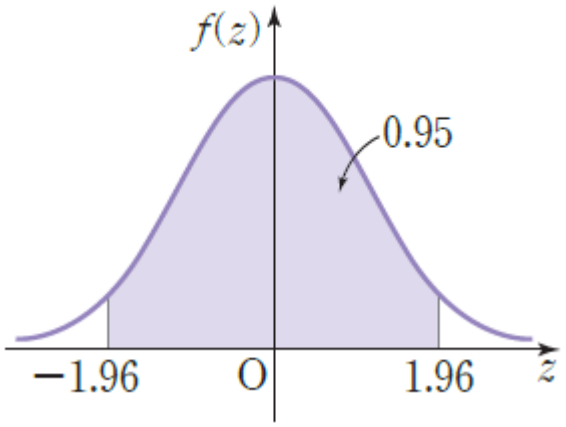
신뢰도



P(-2 ≤ z ≤ 2)=0.954 이므로, P(□≤ z ≤□)=0.95가 되게하는 값 □의 절대값은 2보다 아주 조금 작은 1.96이다.

신뢰도 & 신뢰구간(Confidence interval)

모집단의 분포가 정규분포 $\mathrm{N}(m,\ \sigma^2)$을 따를 때, 크기가 n인 표본을 임의추출하면 표본평균 $\overline{X}$는 정규분포 $\mathrm{N}\left(m,\ \frac{\sigma^2}{n}\right)$을 따르므로 확률변수$Z$는 표준정규분포 $\mathrm{N}(0,\ 1)$을 따른다.



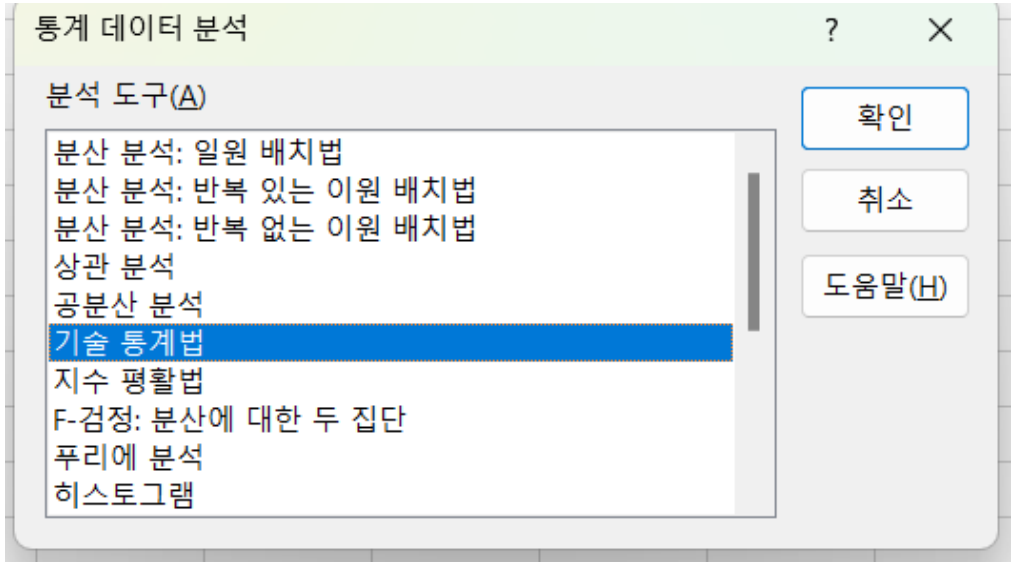
$\mathrm{P}(-1.96 \le Z \le 1.96) = 0.95$ 이므로 $Z = \dfrac{\overline{X} - m}{\dfrac{\sigma}{\sqrt{n}}}$ 를 대입하여

모평균의 신뢰도가 95%인 신뢰구간을 구하면

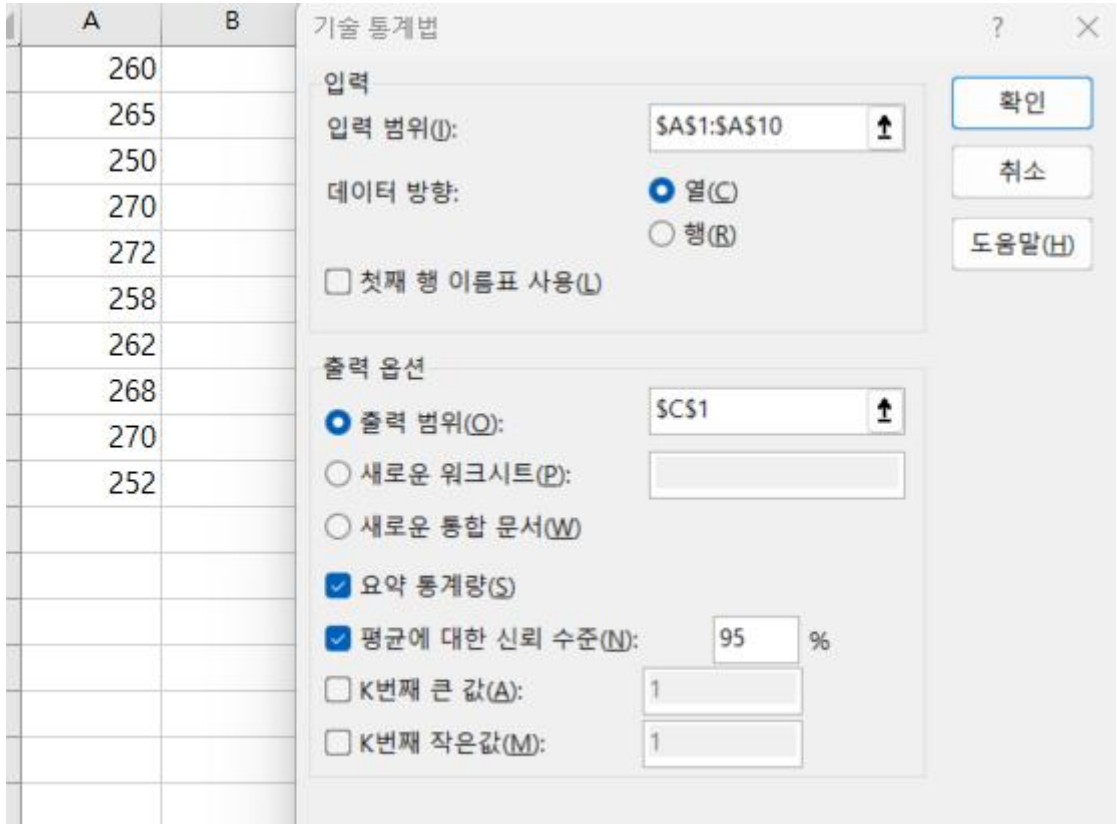
$\overline{x} - 1.96\dfrac{\sigma}{\sqrt{n}} \le m \le \overline{x} + 1.96\dfrac{\sigma}{\sqrt{n}}$, $\overline{x}$ 는 표본평균을 의미함

[연습]

[연습]의 데이터는 A 기업에서 생산한 건전지 10개에 대해 수명(시간)을 조사한 데이터입니다. 이 데이터를 사용하여 A 기업에서 생산하는 건전지의 평균수명을 조사하고자 합니다. 모집단은 정규분포를 따릅니다. 이 데이터로부터 모집단의 평균을 신뢰도 95% 수준에서 계산하세요.



1단계. [데이터]탭➔[데이터 분석]➔[기술통계법] 선택

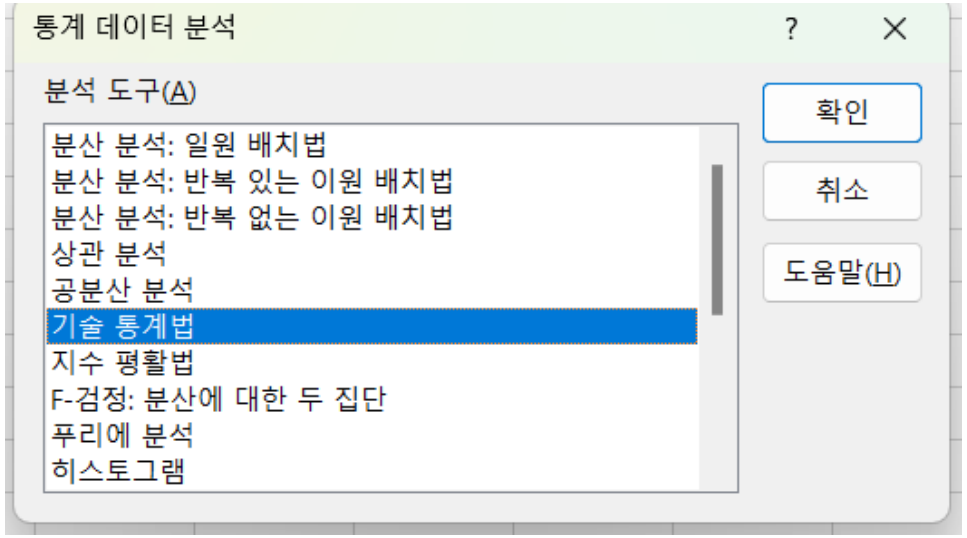


2단계. 데이터 범위 선택과 평균에 대한 신뢰수준 입력

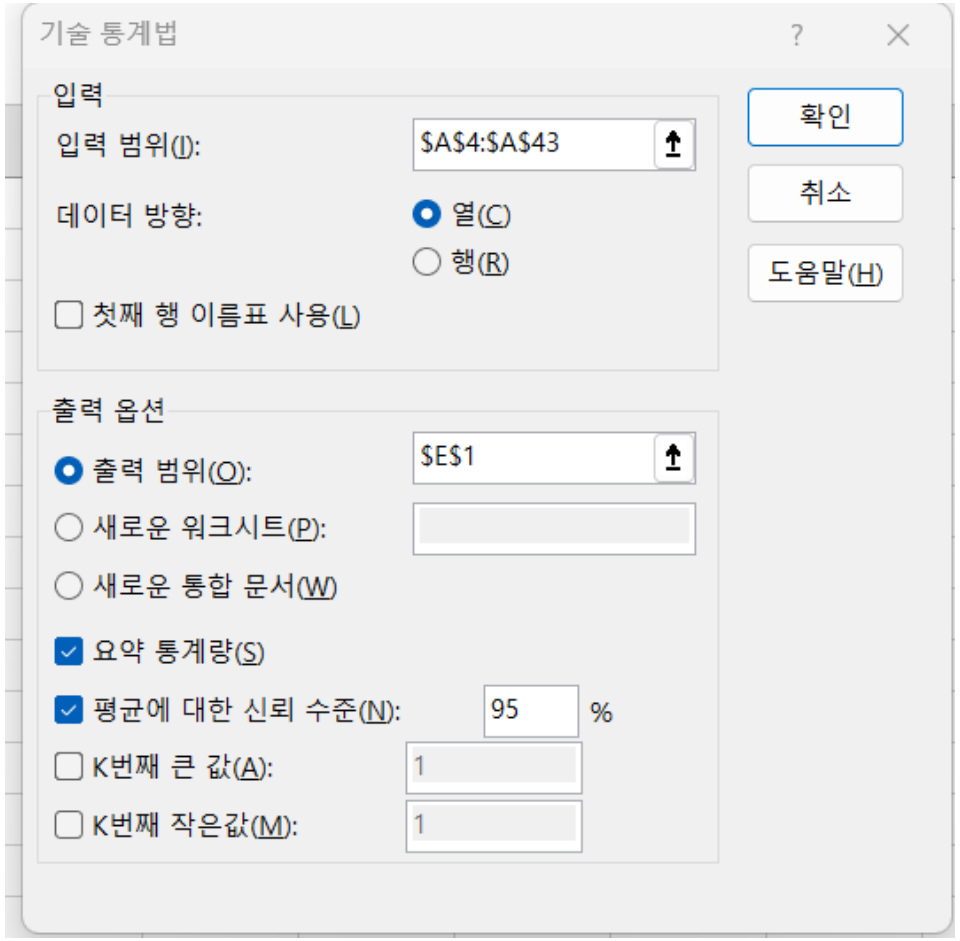
*정답은 [(참고_완성본) 연습] 참고하세요

[실습1]

[실습1]에 있는 데이터는 프로야구 선수 40명의 연봉데이터이다. 모집단인 우리나라 프로야구 선수들의 연봉 데이터는 정규분포를 따른다. 모집단 평균의 신뢰구간을 신뢰도 95% 수준에서 구하세요.



1단계. [데이터]탭➔[데이터 분석]➔[기술통계법] 선택

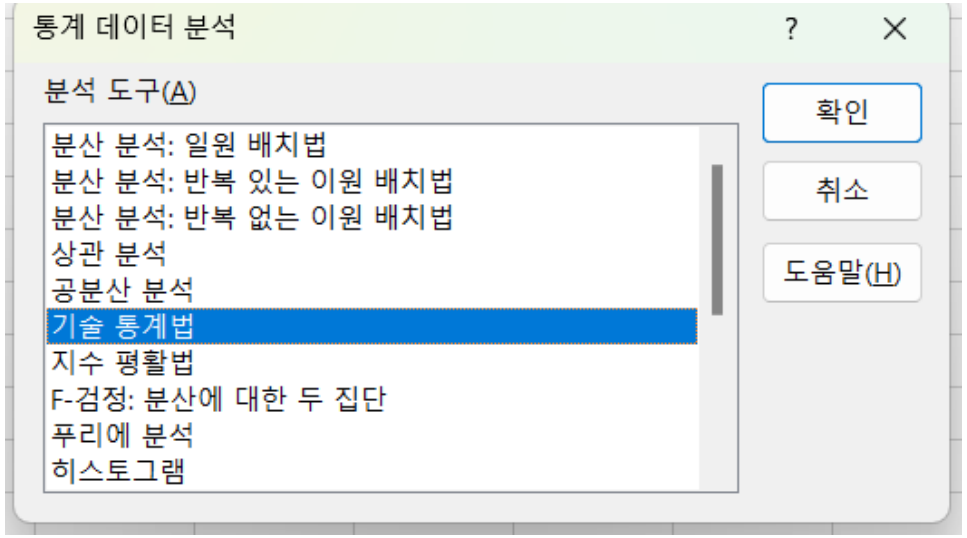


2단계. 데이터 범위 선택과 평균에 대한 신뢰수준 입력

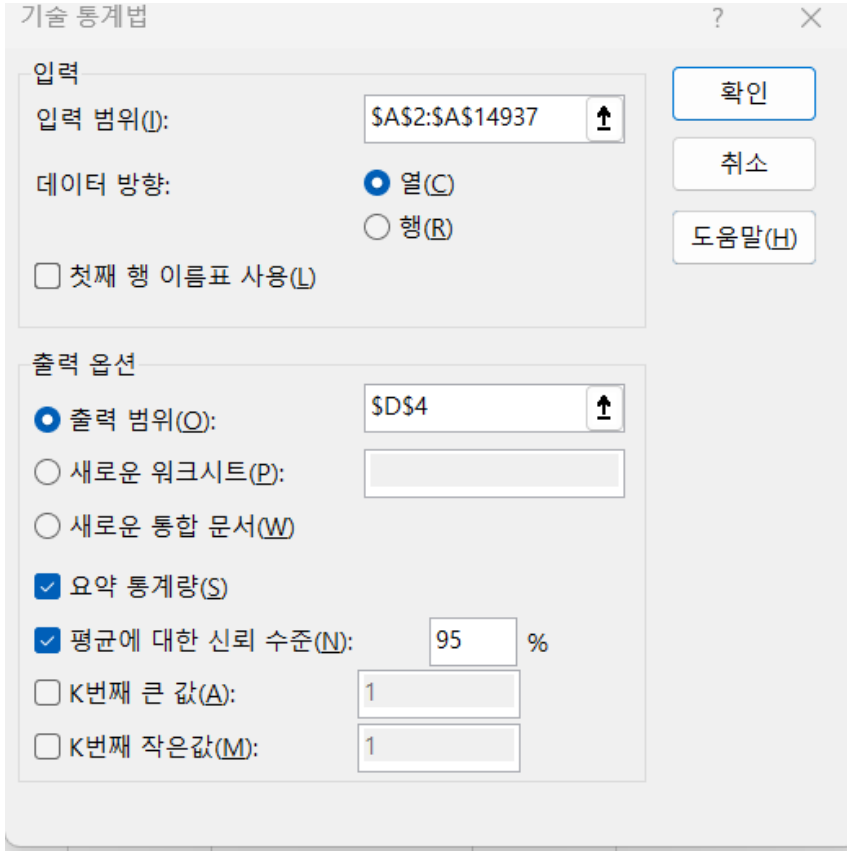
*정답은 [(참고_완성본) 실습1] 참고하세요

[실습2]

[실습2]는 교육부에서 제공한 2019년 학생건강검사 표본통계의 중학생 데이터입니다. 이 데이터를 사용하여 모집단인 우리나라 중학생 키의 평균에 대한 신뢰구간을 구하세요(신뢰수준 95%).



1단계. [데이터]탭➔[데이터 분석]➔[기술통계법] 선택



2단계. 데이터 범위 선택과 평균에 대한 신뢰수준 입력

*정답은 [(참고_완성본) 실습2] 참고하세요